MATH20008h.01 最优化方法 (H) Spring 2026

Lecture 1 最优化引论 — 2026.03.06

教授：郦旭东

Scribe: 路人甲

目录

1 最优化引论 **1**

2 案例分析 **2**

1 最优化引论

我们首先引入最优化问题的基本形式。最优化问题的核心形式通常分为上下两行：第一行是目标函数，第二行是约束条件。一般来说，我们的目标是最小化一个函数 $f(x)$，同时满足一些约束条件，这些约束条件定义了一个可行域 Ω。因此，最优化问题的标准形式可以写为：

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & x \in \Omega \end{aligned}$$

接下来，我们考虑一个特殊的子类——线性规划。它的形式更为简单：

$$\begin{aligned} \min_x \quad & \langle c, x \rangle \\ \text{s.t.} \quad & Ax \leq b \end{aligned}$$

在几何上，这相当于在一个由多面体（即一系列线性不等式约束交叠而成）所构成的区域上，寻找一个线性目标函数的极值点。在本课程中，我们将主要关注更为一般的非线性规划问题，即目标函数 f 和约束函数 g 都可能是非线性的：

- 目标函数 f 可能是二次函数、三次函数，乃至更复杂的神经网络损失函数等。
- 约束函数 g 可能包含球面、矩阵秩约束等非线性结构。

优化的本质是“在有限资源下进行决策”。无论是日常生活中的时间分配，还是工业界的资源调度，本质上都是在约束条件下寻求目标函数的最优解。优化问题的标准处理范式通常遵循如下链

路：数学建模 (Modeling) → 算法设计 (Algorithm) → 测试与验证 (Test)。建模是最困难的一步，建模的质量直接决定了后续算法设计和测试的成效。测试这一步往往涉及与底层硬件、操作系统的配合。工业界在这两个环节中具有显著优势，而学术界则在算法设计方面更具优势。本课程将主要关注算法设计这一核心模块。

对于非线性规划，我们通常要求目标函数 $f(x)$ 是足够光滑的。一个自然的设定是要求它至少连续可微，有时为了利用二阶曲率信息，我们甚至需要假设 $f \in C^2$. 同时，约束集 Ω 可以具体地表示为不等式组的形式：

$$\Omega = \{x \in \mathbb{R}^n : g(x) \leq 0\}, \quad g : \mathbb{R}^n \to \mathbb{R}^m, \quad g_i \in C^2.$$

如果可行域 $\Omega = \mathbb{R}^n$，我们称这类问题为无约束优化 (Unconstrained)；否则，就是带约束优化 (constrained)。

在本课程接下来的学习中，我们将主要围绕以下三个核心模块展开：

- 基本概念 (Basic notion)；
- 最优性条件 (optimality condition)：所谓的最优性条件其实和数值算法里的停机准则很类似。在迭代法（如共轭梯度法）中，停机条件通常是残差的范数小于容差 ε. 但是，在优化问题中，这个所谓的“停机准则”往往没有线性问题中那么明确。或许有同学会考虑相邻两项之间的距离 $\|x_{k+1} - x_k\|$，停机准则是这个距离小于容差；但这并不合理：$x^* = x_1 + \sum_{n=1}^{\infty}(x_{n+1} - x_n)$，$\|x_{n+1} - x_n\| \to 0$ 并不意味着级数会收敛，这只是一个必要条件而非充分条件。因此，什么是最优性条件，是我们需要慎重考虑的问题。
- 求解算法 (Algorithms)。

2 案例分析

这门课其实叫《最优化方法与案例分析 *(H)*》。

2.1 例

为了更直观地理解，我们来看一个经典的金融学应用：投资组合选择 (Portfolio selection)。在这个问题中，我们需要决定如何将资金分配到多种不同类型的资产中。假设我们有 n 种资产，每种资产的收益率 r_i 是一个随机变量。我们已知其期望收益为 $\mathbb{E}r_i = \mu_i$，方差为 $\mathrm{Var}(r_i) = \sigma_i^2$. 现在，我们希望找到一种合理的投资策略。

我们进一步定义不同资产收益率之间的协方差如下：

$$\mathrm{corr}(r_i, r_j) = \mathbb{E}(r_i - \mu_i)(r_j - \mu_j) = \rho_{i,j}$$

设 x_i 为我们在第 i 种资产上的投资比例。显然，我们的投资总额受到归一化约束，且不允许做空：

$$\begin{aligned}&\sum_{i=1}^{n} x_i = 1\\&x_i \geq 0, \quad i = 1, \ldots, n\end{aligned}$$

我们记 $s = \begin{bmatrix} r_1 & r_2 & \cdots & r_n \end{bmatrix}^\top$ 此时，我们整个投资组合的总收益 r 及其期望可以线性地表示为：

$$r = \sum_{i=1}^{n} x_i r_i, \quad \mathbb{E}[r] = \mathbb{E}[x^\top s] = x^\top \mu.$$

那么，如何衡量投资的风险呢？“风险”其实可以由方差来度量。

$$\mathrm{Var}(r) = \mathbb{E}(r - \mathbb{E}r)^2 = x^\top Q x, \quad \text{where } Q_{ij} = \rho_{ij}\sigma_i\sigma_j \to \text{risk}.$$

那么，什么样的投资组合策略叫“合理”呢？一个自然的想法是：在保证预期收益不低于给定阈值 $\bar{r}$ 的前提下，我们如何将风险降到最低？这便引导我们写出了如下的 Markowitz 均值–方差优化模型：

$$\begin{aligned}\min \quad & x^\top Q x\\\text{s.t.} \quad & x^\top \mu \geq \bar{r}\\&\sum_{i=1}^{n} x_i = 1\\&x_i \geq 0, \quad i = 1, \ldots, n\end{aligned}$$

这是一个非常经典的二次规划问题。我们将在后续课程中学习其求解算法。

当然，对于各位股神读者们来说，我们肯定不会满足于利润仅仅是不低于某个阈值而已：如果在我们可承受的最大风险 $\bar{\sigma}^2$ 的限度内，我们要如何最大化预期收益——这才是大多数人真正关心的问题。这个问题的数学表达式如下：

$$\begin{aligned}\max \quad & x^\top \mu\\\text{s.t.} \quad & x^\top Q x \leq \bar{\sigma}^2\\&\sum_{i=1}^{n} x_i = 1\\&x_i \geq 0, \quad i = 1, \ldots, n\end{aligned}$$

注：两个建模方式其实是对偶的：目标函数和约束条件位置颠倒了。从某种意义上来说，对偶意味着某种等价性。在某些条件下，两个问题的解可能是相同的。

A 股数据太不靠谱！害我亏钱了！ —— lxd

2.2 例

接下来，我们考虑机器学习中另一个极具代表性的例子：支持向量机 (SVM)。给定一组二分类的训练数据集：$\{(x_i, y_i)\} \subseteq \mathbb{R}^p \times \{+1, -1\}$
我们希望找到一个映射关系 f，将包含诸多特征（如性别、年龄等）的输入特征向量 $x_i \in \mathbb{R}^p$ 映射到确定的标签 $y_i \in \{+1, -1\}$：

$$x_i \in \mathbb{R}^p \quad \begin{pmatrix} \text{sex} \\ \text{age} \\ \vdots \end{pmatrix} \xrightarrow{f} y_i \in \{+1, -1\}$$

为了简化问题，我们假设该分类器是线性的，即 $f(x) = w^\top x + b$。我们的预测规则可以形式化地写为：

$$y = \begin{cases} +1, & \text{if } w^\top x + b > 0 \\ -1, & \text{if } w^\top x + b \leq 0 \end{cases}$$

此时，决策超平面的方程为 $w^\top x + b = 0$。对于空间中的任意一点 $\hat{x}$，它到该分类超平面的几何距离 d 可以表示为：

$$d = \frac{|w^\top \hat{x} + b|}{\|w\|_2}$$

那么，怎样的超平面才是“最好”的呢？我们希望所有样本点到超平面的最小几何距离能够尽可能地大（即最大化分类间隔）。这就导出了如下的最优化问题：

$$\max_{w,b} \min_{i=1,\ldots,n} \frac{|w^\top x_i + b|}{\|w\|_2}$$

注意到 $d_i = |w^\top x_i + b|/\|w\|_2 = y_i(w^\top x_i + b)/\|w\|_2$，因为 $y_i = \pm 1$ 且与 $w^\top x_i + b$ 同号。于是上面的优化问题可以写为

$$\max_{w,b} \min_{i=1,\ldots,n} \frac{y_i(w^\top x_i + b)}{\|w\|_2}.$$

值得注意的是，这个目标函数关于参数 (w, b) 是尺度无关的 (scale-free)。

这个优化问题非常难以求解，我们需要考虑将其转化为一种等价的、但易于求解的形式。既然具有尺度不变性，我们完全可以通过缩放法向量和偏置参数，强制要求离超平面最近的点的函数间隔恰好为 1，即假设：$\min_{i=1,\ldots,n} y_i(w^\top x_i + b) = 1$.

这样一来，最大化距离 $\frac{1}{\|w\|_2}$ 就完全等价于最小化 $\frac{1}{2}\|w\|_2^2$。经过这一步转化，我们便得到了硬间隔 SVM 的标准形式：

$$\begin{aligned} \min_{w} \quad & \frac{1}{2}\|w\|_2^2 \\ \text{s.t.} \quad & y_i(w^\top x_i + b) \geq 1, \quad i = 1, 2, \ldots, n \end{aligned}$$

此时，模型的可行域为：$F = \{(w, b) : y_i(w^\top x_i + b) \geq 1\}$

但是，如果训练数据本身并不是线性可分的呢？很可惜的是，上述可行域 F 此时将为空集。为了允许一定的错分，我们引入惩罚项，得到带有合页损失的无约束形式：

$$\min \frac{1}{2}\|w\|_2^2 + \lambda \sum_{i=1}^{n} \max\{1 - y_i(w^\top x_i + b), 0\}.$$

这里 $\lambda > 0$ 是一个超参数。一个自然的问题随之而来：这个带有惩罚项的目标函数是可微的吗？显然，由于 max 函数的存在，它是非光滑的不可微函数。这与我们先前约定的“目标函数需要足够光滑”这一设定相悖。那么，我们该如何求解这个非光滑的优化问题呢？

为了克服不可微带来的求解困难，我们引入松弛变量 t_i，将无约束的非光滑问题重新等价转化为一个光滑的带约束二次规划问题：

$$\begin{aligned} \min_{w} \quad & \frac{1}{2}\|w\|_2^2 + \lambda \sum_{i=1}^{n} t_i \\ \text{s.t.} \quad & t_i \geq 1 - y_i(w^\top x_i + b), \quad i = 1, 2, \ldots, n \\ & t_i \geq 0, \quad i = 1, 2, \ldots, n \end{aligned}$$

这种引入辅助变量的技巧，极大地方便了后续成熟优化算法的直接调用。

最后，我们稍微拓展一下这种重构思想。如果我们在一般的损失函数 $\ell(x)$ 上添加 ℓ_1 范数正则化项，即求解：

$$\min \ell(x) + \lambda\|x\|_1, \quad x = x^+ - x^-, \quad \|x\|_1 = e^\top x^+ + e^\top x^-$$

我们同样可以利用变量分离分解 $x = x^+ - x^-$ 的技巧，将不可微的 ℓ_1 范数巧妙地转化为线性约束形式，从而继续利用成熟的框架进行求解。