MATH20008h.01 最优化方法 (H) Spring 2026

Lecture 2 最优化基础 — 2026.03.13

教授：郦旭东

Scribe: 路人甲

目录

1 最优化问题的基本概念 **1**

2 最优性条件 **4**

2.1 高维微积分复习 4

2.2 最优性的必要性条件与充分性条件 6

1 最优化问题的基本概念

我们首先给出一个一般性的非线性优化问题：

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & h_i(x) = 0, \quad i = 1, \cdots, p \\ & g_j(x) \le 0, \quad j = 1, \cdots, m \end{aligned}$$

这里我们假设目标函数和约束函数都是连续可微的，即 $f, h_i, g_j \in C^1$. 相应的可行域定义为 $\Omega = \{x : h_i(x) = 0, g_j(x) \le 0\}$。显然，由于约束函数是连续的，所以对应的等式与非严格不等式约束截出的可行集 Ω 是一个闭集。等式约束是很严格的，等式约束的可行解可以由二分法、割线法、牛顿法等得到，详见数值二 Lecture 1.

对于不等式约束，为什么我们通常不使用严格不等式 $g_j(x) < 0$ 作为约束条件呢？我们不妨考虑这种情况：设 $x_0 \in \Omega$，且满足 $g_j(x_0) < 0$。由于连续性，必然存在一个足够小的邻域，即存在 $\delta > 0$，使得对于所有满足 $\|\Delta\| < \delta$ 的摄动，都有 $g_j(x_0 + \Delta) \le 0$. 这意味着严格不等式约束所限定的集合是一个开集，而开集上的极值问题无法在其边界上取到极值，这会导致问题缺乏良好的性质。因此，这是一种不太好的约束条件。

现在，我们来给出最优解的定义。

1.1 定义 最优解

我们定义上面优化问题的最优值为 $f^* = \inf_{x\in\Omega} f(x)$. 如果存在某个点 $x^* \in \Omega$，使得 $f(x^*) = f^*$，那么我们就称 x^* 为最优解。

但是，最优解一定存在吗？很可惜的是，最优解 x^* 可能根本不存在。举个简单的反例：

$$\min_{x\in\mathbb{R}} \mathrm{e}^{-x} = 0 = f^*, \text{ 但 } x^* \text{ 不存在。}$$

有关最优解，我们有两个概念需要区分：局部极小值与全局最小值。

1.2 定义 局部极小值、全局最小值

1. 局部极小值定义为：如果存在 $x^* \in \Omega$，使得对任意 $x \in B_\delta(x^*) \cap \Omega$，都有 $f(x) \geq f(x^*)$，则称 x^* 为局部极小值点。
2. 全局极小值则是在整个可行域上满足上述不等式。

此外，优化问题还有两种异常情况：当可行集 $\Omega = \emptyset$ 时，问题被称为**不可行**的，对应最优值约定为 $f^* = +\infty$；当目标函数在可行集上向下无界时，即最优值 $f^* = -\infty$，问题被称为无界的。

为了后续讨论方便，我们考虑如下更紧凑的形式：

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & x \in \Omega \end{aligned}$$

其中 Ω 为有界闭集。接下来，我们将在此基础上讨论最优解存在的必要性条件。

1.3 定理 *Weierstrass* 定理

若 $\Omega \neq \emptyset$ 且为有界闭集（即紧集），同时 f 是连续函数，则必然存在 $x^* \in \Omega$，使得 $f(x^*) = \min_{x\in\Omega} f(x)$。

这个定理实际上是我们过去所熟知的结论：函数在有界闭集上一定能取到最小值。然而，在实际的优化问题中，有界条件常常是无法满足的。那么，如果可行域无界，我们该如何判断最优解的存在性呢？我们不妨从一些已知存在最优解的函数出发，归纳其特点，然后证明符合这一特点的函数都可以取到最小值。一次函数可以发散到负无穷；除了一次函数外，最简单的函数当属二次函数，我们不妨考虑二次规划

$$\begin{aligned} \min \quad & \frac{1}{2}\langle x, Qx\rangle + \langle c, x\rangle \\ \text{s.t.} \quad & x \in \Omega \quad \Omega\text{是闭集。} \end{aligned}$$

显然当 $Q \succeq 0$ 时函数能取到最小值。那么这样的函数有什么特点呢？我们知道，二次函数在自变量范数趋于无穷时，因变量也趋于无穷。那么，最小值所在区间一定是有界的：否则若范数过大，函数值就会发散到无穷大。在这一条件下，从直觉上来说，最优解就被控制在了一个有界闭集内——根据 Weierstrass 定理，有界闭集肯定是能找到最小值点的。直觉告诉我们，这样的函数是有希望能找到最优解的。这就引出了强制（coercive）函数的概念：

1.4 定义 强制函数

设函数 $f : \mathbb{R}^n \to \mathbb{R}$ 满足

$$\lim_{\|x\| \to \infty} f(x) = +\infty$$

则称 f 为强制函数。

下面我们就来证明强制函数在闭集上能找到最优解。

1.5 定理

若 $\Omega \neq \emptyset$ 且为闭集，f 是连续且强制的，则该优化问题 $\min_{x \in \Omega} f(x)$ 存在最优解。

证明. 我们来严格推导这个定理。由于可行集非空即，我们可以任取一点 $x_0 \in \Omega$，并记 $\alpha = f(x_0) \in \mathbb{R}$.

接下来，我们构造一个下水平集（level set）： $S_\alpha := \{x \in \Omega : f(x) \leq \alpha\}$. 因为 f 是连续函数且 Ω 是闭集，所以这个下水平集 S_α 必然也是闭集。

利用强制函数的性质，必定存在某个正数 δ，使得对于所有的 $\|x\| > \delta$，都有 $f(x) \geq \alpha + 1$。这就意味着，下水平集必须被包含在一个有界球内，即得出推论 $S_\alpha \subset \{x : \|x\| < \delta\}$。因此，我们证明了 S_α 是一个有界闭集。

在有界闭集 S_α 上应用 Weierstrass 定理，必然存在极小值点：

$$\exists x^* = \arg\min_{x \in S_\alpha} f(x)$$

现在我们只需证明，对于全局范围内的任意点，这个极小值也是成立的，即证 $f(x) \geq f(x^*)$，$\forall x \in \Omega$. 注意到，如果我们取 $x \in \Omega \setminus S_\alpha$，根据下水平集的定义，有 $f(x) > \alpha$. 又因为 $x_0 \in S_\alpha$，极小值的定义保证了 $\alpha \geq f(x^*)$. 由此串联不等式得到 $f(x) > \alpha \geq f(x^*)$. 而对于 $x \in S_\alpha$，根据 x^* 在 S_α 上的极小值定义，显然也有 $f(x) \geq f(x^*)$. 综上所述，x^* 即为全局最优解。 □

在这段证明中，我们实际上采用了一种非常精妙的截断思想：通过引入强制性条件，我们在无界的可行域中划定了一个“有界闭集”（即下水平集）。因为在无穷远处的函数值足够大，真正的最优

解必然被“逼”回到这个有界的下水平集区域内，从而将无界问题巧妙地转化为了有界闭集上的优化问题。

另外值得补充的是，如果我们对所有可能的函数取值划定下水平集，并考察它们的交集

$$\bigcap_{\alpha \in f(\Omega)} S_\alpha = \Omega^*$$

显然这正是最优解集。但如果函数的下确界不可达，这个集合可能是 $\emptyset$. 例如前面提到过的 $\mathrm{e}^{-\|x\|_2}$，如果假定 Ω 是全空间，那么上面的交集将会是空集。

2 最优性条件

在引入最优性条件之前，我们需要先复习一下高维微积分。

2.1 高维微积分复习

考虑一个一般的可微映射 $F : \mathbb{R}^n \to \mathbb{R}^m$. 我们有如下的一阶 Taylor 展开：

$$F(x+h) - F(x) = F'(x) \cdot h + o(\|h\|), \quad \text{其中 } F'(x) \in \mathbb{R}^{m \times n} \text{ 为线性映射}$$

这在极限意义下等价于：

$$\lim_{\|h\| \to 0} \frac{F(x+h) - F(x) - F'(x) \cdot h}{\|h\|} = 0.$$

特别地，当 $m = 1$ 时，我们面对的是标量实值函数，此时导数矩阵为行向量 $F'(x) \in \mathbb{R}^{1 \times n}$. 我们更习惯使用列向量，因此我们定义梯度向量为它的转置：令 $\nabla f(x) = (F'(x))^\top$。于是上述展开可以写为熟悉的内积形式：

$$F(x+h) = F(x) + \langle \nabla f(x), h \rangle + o(\|h\|).$$

事实上，很多时候在求导数时，我们可以将函数展开成上述形式，提取内积项，就可以找到函数在某点的导数。为了加深理解，我们来看几个计算梯度的经典例子。

对于二次型 $f(x) = \frac{1}{2}\langle x, Qx \rangle + \langle c, x \rangle$，考虑

$$\begin{aligned} f(x+h) &= \frac{1}{2}\langle x+h, Q(x+h) \rangle + \langle c, x+h \rangle \\ &= \frac{1}{2}(\langle x, Qx \rangle + \langle h, Qx \rangle + \langle x, Qh \rangle + \langle h, Qh \rangle) + \langle c, x \rangle + \langle c, h \rangle \\ &= f(x) + \left\langle \frac{1}{2}(Q + Q^\top)x + c, h \right\rangle + o(\|h\|) \end{aligned}$$

因此

$$\nabla f(x) = \frac{Q + Q^\top}{2} x + c.$$

再考虑一个矩阵函数 $f(X) = \log\det(X)$，其中自变量 $X \succ 0$. 为了求 $\nabla f(X)$，我们对自变量施加一个微小的扰动 H，并将行列式展开：

$$f(X+H) = \log\det(X+H) = \log\big(\det X \cdot \det(I + X^{-1}H)\big) = f(X) + \log\det(I + X^{-1}H).$$

注意到，矩阵行列式的扰动可以利用特征值展开进行近似估算：

$$\begin{aligned}\det(I+tH) &= \prod_{i=1}^{n}(1+t\lambda_i) \\ &= 1 + t\cdot\mathrm{tr}(H) + o(t)\end{aligned}$$

同理将其代入，我们得到：

$$\det(I + X^{-1}H) = 1 + \mathrm{tr}(X^{-1}H) + o(\|H\|)$$

于是目标函数的增量可以展开为：

$$\begin{aligned}f(X+H) &= f(X) + \log(1 + \mathrm{tr}(X^{-1}H) + o(\|H\|)) \\ &= f(X) + \mathrm{tr}(X^{-1}H) + o(\|H\|) \\ &= f(X) + \langle X^{-1}, H\rangle_F + o(\|H\|).\end{aligned}$$

这里我们把矩阵乘积的迹理解为矩阵的 Frobenius 内积，即将两个矩阵拉伸成向量后两个向量的内积。对比一阶 Taylor 展开式的定义，我们显然得出结论：

$$\nabla f(X) = X^{-1}.$$

在上面，我们对行列式 $\det(I + X^{-1}H)$ 做了展开。请读者注意，这个一阶近似相当重要。

现在我们将梯度的概念延伸到 L 层的深度神经网络中。考虑前向传播的递归形式：初始输入 $a_0 = x$，每一层的线性组合和激活函数可以表示为 $z_l = W_l a_{l-1} + b_l$，且 $a_l = \sigma_l(z_l)$。最终的输出为 $F(x) = a_L$，对应的损失函数为 $\mathcal{L}(x) = \ell(F(x))$。在训练网络时，我们实际上是在解决如下的优化问题：

$$\min_{W,b} \quad \mathcal{L}(x; W, b)$$

我们需要计算关于参数的梯度：$\nabla_W \ell(x; W, b)$ 和 $\nabla_b \ell(x; W, b)$。这正是大名鼎鼎的反向传播算法（Back Propagation）所做的事情。此外，如果我们想要计算二阶导数信息，即 Hessian 矩阵。直接计算完整的 Hessian 矩阵代价极大，但在实际应用中，通常只需计算 Hessian 矩阵与一个向量的乘积，记作 Hh——换句话说，我们只需要求出算子 H. 通过某些算法，Hessian 的计算量能做到与一次反向传播相当——尽管这看起来相当反直觉。

但是，如果我们想要利用链式法则手推梯度，我们可能会遇到一些问题：

1. 激活函数 $\sigma_l : \mathbb{R}^n \to \mathbb{R}^n$ 可能不可微。例如，ReLU 的激活函数是 $\sigma(x) = \max(x, 0)$，这显然不可微。

2. 即使激活函数可微，它的导数是一个 $n \times n$ 的 Jacobi 矩阵——光是存储就很费劲了！

反向传播巧妙地规避了第二点困难，但第一点困难确实无法避免，但是因为遇到精确不可导点的概率极低，通常不会影响训练。此外，算法还采用了一些启发式的自动微分方法，虽然其严格性有待商榷，但在实践中效果很好。

2.2 最优性的必要性条件与充分性条件

有了这些微积分工具，我们正式讨论最优性的必要与充分条件。

- 一阶必要条件

2.1 定理

如果 x^* 是无约束优化问题 $\min_{x\in\mathbb{R}^n} f(x)$ 的局部极小值点，则必然有其梯度为零，即 $\nabla f(x^*) = 0$。

证明. 既然 x^* 是局部极小值，根据定义，必定存在邻域半径 $\delta > 0$，使得对于所有的 $x \in B_\delta(x^*)$，都有 $f(x) \geq f(x^*)$。

我们采用反证法来证明。假设 $\nabla f(x^*) \neq 0$。沿着负梯度方向进行泰勒展开：

$$f(x^* + td) = f(x^*) + \langle \nabla f(x^*), td \rangle + o(t)$$

令下降方向 $d = -\nabla f(x^*)$，代入上式得到：

$$f(x^* + td) = f(x^*) - t\|\nabla f(x^*)\|^2 + o(t)$$

当步长 $t \to 0$ 时，高阶小量可以忽略，一阶项占主导地位，因此必然有严格下降 $f(x^* + td) < f(x^*)$。这与 x^* 是局部最优解的假设矛盾！ □

这个反证法直观地告诉我们：只要梯度不为零，我们总能沿着负梯度的反方向迈出一小步，从而找到一个更小的函数值。这也是梯度下降法（Gradient Descent）最朴素的思想来源。

但是，这里有一个值得深思的细节：如果可行集 Ω 不是全空间，而是某个开集，一阶条件会有什么不同吗？答案是，在一阶稳定点意义下，**开集约束本质上是没有意义的**。由于 Ω 是开集，只要步长 t 足够小，我们沿着负梯度方向移动的点依然会严格留在集合内部，即

$x - t\nabla f(x^*) \in \Omega$。因此，不论你写出多少行开集约束条件，只要极值点没有贴着边界，它的梯度依然必须是零。

为了进一步说明，我们考虑另一个经典问题：

$$\min_{x\in\mathbb{R}^n} \quad \frac{1}{2}\|Ax-b\|_2^2 + \lambda\|x\|_1$$

这是一个本质上有约束的优化问题。尽管它表面上写成了无约束的形式，但由于 ℓ_1 范数在原点处不可微，使得问题产生了类似于绝对约束的折点。可以说，**可微性**正是区分有无约束优化的核心关键所在。

- 二阶必要条件

2.2 定理

若 x^* 是 $\min_{x\in\mathbb{R}^n} f(x)$ 的局部极小值点，则不仅有 $\nabla f(x^*) = 0$，而且其 Hessian 矩阵必须是半正定的，即 $H_f(x^*) \succeq 0$。

我们简单分析一下推导逻辑。沿着任意方向 h 进行二阶泰勒展开，并考虑到一阶梯度已经为 0：

$$f(x^* + th) = f(x^*) + \frac{1}{2}t^2\langle h, H_f(x^*)h\rangle + o(t^2)$$

要使局部极小值条件 $f(x^* + th) \geq f(x^*)$ 成立，当 t 足够小时，对应的二阶项必须非负：

$$\frac{1}{2}t^2\langle h, H_f(x^*)h\rangle + o(t^2) \geq \frac{1}{3}t^2\langle h, H_f(x^*)h\rangle \geq 0$$

这直接要求了二次型非负，即推导出 $H_f(x^*) \succeq 0$。

很可惜的是，尽管二阶必要条件的理论要求是特征值非负，但在实际工程的数值计算中往往非常难判断。例如，如果我们算出一个特征值 $\lambda = -10^{-15}$，受限于计算机的浮点数精度，我们很难断定它究竟是理论上的 0（由于截断误差导致的极小负数）还是真实存在的负数方向。

最后，我们给出二阶充分条件。满足一阶必要条件后，如果 Hessian 矩阵具有更严格的正定性，我们就能断定它是严格的局部极小值。

2.3 定理

如果极值点满足 $\nabla f(x^*) = 0$，且 Hessian 矩阵严格正定 $H_f(x^*) \succ 0$，则 x^* 必定是一个严格的局部极小值。

证明. 因为 $H_f(x^*) \succ 0$，意味着其最小特征值严格大于零，即 $\lambda_{\min} > 0$。根据连续性，必然存在一个局部的区域：即存在 $\alpha > 0$ 以及 $\delta > 0$，使得对于任意的 $x \in B_\delta(x^*)$，都有：

$$f(x) \geq f(x^*) + \frac{1}{2}\alpha\|x - x^*\|^2$$

我们可以通过 Taylor 展开来进行更加严格的证明。设位移量 $d = x - x^*$，展开得：

$$f(x^* + d) = f(x^*) + \langle \nabla f(x^*), d\rangle + \frac{1}{2}\langle d, H_f(x^*) \cdot d\rangle + o(\|d\|^2).$$

代入驻点条件 $\nabla f(x^*) = 0$，并利用 Rayleigh 商的性质，我们可以将二次型下界进行放缩：

$$f(x^* + d) \geq f(x^*) + \frac{1}{2} \cdot \lambda_{\min} \cdot \|d\|_2^2 + o(\|d\|^2) > f(x^*)$$

因此，在足够小的邻域内（使得余项无法抵消二阶主部），函数值严格大于 $f(x^*)$。证毕。 □

在这段证明的最后，我们巧妙地使用了 Rayleigh 商放缩。Hessian 矩阵的严格正定性从几何上保证了函数在驻点附近是一个开口向上且曲率严格为正的“碗”形结构，从而确立了严格局部最优的充分性。