MATH20008h.01 最优化方法 (H) Spring 2026

Lecture 4 梯度算法收敛性 — 2026.03.27

Lecturer: 郦旭东

Scribe: 路人甲

关于算法的收敛性，在以前的理论分析中我们更关心当迭代步数趋于 ∞ 时的渐近性质。但在实际应用中，受限于有限的算力，我们现在更关心在有限步内算法的收敛表现如何。例如，在训练一个深度神经网络时，迭代一步的成本都特别高昂，因此我们更希望在有限的迭代次数内就能得到一个足够好的解。

本门课程仍然关注的是传统的收敛性分析。具体来说，我们关心序列 $\{x^k\}_{k=1}^{+\infty}$ 是否收敛；如果收敛，它的收敛速度又如何？

首先，我们来看看 Armijo 准则的收敛性。为分析 Armijo 准则的收敛性，我们需要引入一个新的概念：梯度相关方向。

0.1 定义 梯度相关方向

对于迭代序列 $\{x^k\}$ 和方向序列 $\{d^k\}$，如果在任意收敛子列 $\{x^k\}_{k\in K} \to \bar{x}$ 上，只要 $\nabla f(\bar{x}) \neq 0$，就有子列 $\{d^k\}_{k\in K}$ 有界，并且满足 $\limsup_{k\in K} \nabla f(x^k)^\top d^k < 0$，那么我们就称 $\{d^k\}$ 是梯度相关的方向。

或许有人可能会问：我们为什么要引入这个定义呢？难道我们不能直接用负梯度方向吗？答案是不太可能。在实际优化问题中，我们不太可能总是能够直接获取或使用完美的负梯度方向 $d^k = -\nabla f(x^k)$. 例如在存在数据噪声或是使用随机梯度的情况下，我们只能得到一个近似的下降方向。引入“梯度相关方向”这一概念，为我们提供了一个更具强健性的理论框架，它本质上要求搜索方向在极限意义下仍能与负梯度保持一个锐角，而非完全垂直，从而保证了算法在迭代过程中始终朝着下降的方向前进。

在引入了梯度相关方向的概念后，我们就可以得到 Armijo 准则的一个重要收敛性结论：

0.2 定理

如果算法采用 Armijo 准则选取步长，并且搜索方向 $\{d^k\}$ 是梯度相关的，那么序列 $\{x^k\}$ 的每一个极限点都是目标函数 f 的稳定点。

很可惜的是，这个定理并没有保证极限点一定存在。因此，由于缺乏极限点存在性的保障，这个收敛性结论本身是相对较弱的。

证明. 我们利用反证法来证明这一结论。首先，根据 Armijo 准则的定义，我们有

$$f(x^{k+1}) \leq f(x^k) + c_1\alpha_k \nabla f(x^k)^\top d^k.$$

由于方向是下降的，对于任意的 $k \in \mathbb{N}$，都有 $f(x^{k+1}) \leq f(x^k)$，这意味着目标函数值序列 $\{f(x^k)\}$ 是单调递减的。

我们知道单调有界序列必然收敛。但此处序列 $\{f(x^k)\}$ 有可能是无界的。为了便于讨论，我们假设该序列有下界，即 $\{f(x^k)\} \downarrow \bar{f} \in \mathbb{R}$. 我们暂时不考虑无界情况。

假设定理结论不成立，即假设存在一个收敛子列 $\{x^k\}_{k\in K} \to \bar{x}$，但其极限点 $\bar{x}$ 的梯度 $\nabla f(\bar{x}) \neq 0$. 由于搜索方向是梯度相关的，由定义可知，存在 $\sigma > 0$，使得当 $k \in K$ 足够大时，有

$$\nabla f(x^k)^\top d^k \leq -\sigma < 0.$$

既然内积项严格小于零，我们想要 $f(x^k)$ 收敛，就必须让步长 α_k 逐渐趋于零。

根据 Armijo 准则中的回溯机制，这意味着在最后一次压缩之前的步长 $\frac{\alpha_k}{\rho}$ 并不满足充分下降条件，即我们有如下不等式：

$$f\left(x^k + \frac{\alpha_k}{\rho} d^k\right) > f(x^k) + c_1 \frac{\alpha_k}{\rho} \nabla f(x^k)^\top d^k.$$

下面我们就来证明这个不等式。

由微分中值定理可知，存在 $\theta_k \in (0,1)$，使得等式左侧的增量可以由某一点的梯度与方向的内积表示，即有

$$f\left(x^k + \frac{\alpha_k}{\rho} d^k\right) - f(x^k) = \nabla f\left(x^k + \theta_k \frac{\alpha_k}{\rho} d^k\right)^\top \left(\frac{\alpha_k}{\rho} d^k\right).$$

从而有

$$\nabla f\left(x^k + \theta_k \frac{\alpha_k}{\rho} d^k\right)^\top d^k \geq c_1 \cdot \frac{\alpha_k}{\rho} \nabla f(x^k)^\top d^k.$$

由于 $\{d^k\}_{k\in K}$ 是有界的，根据 Weierstrass 定理，必定存在一个收敛子列使得 $d^{k'} \to \bar{d}$. 在此子列上令 $k' \to \infty$，利用梯度的连续性，我们可以得到

$$\nabla f(\bar{x})^\top \bar{d} \geq c_1 \cdot \frac{\alpha_{k'}}{\rho} \nabla f(\bar{x})^\top \bar{d}.$$

由于 $c_1 \in (0,1)$，且 $\alpha_{k'} \to 0$，这直接蕴含着 $\nabla f(\bar{x})^\top \bar{d} \geq 0$. 但这与我们之前利用梯度相关方向推导出的严格小于零的结论产生了矛盾！

因此 α_k 不趋于零，即存在 $\alpha > 0$，使得对于所有的 $k \in K$，都有 $\alpha_k \geq \alpha > 0$. 此时，根据目标函数的单调递减性质以及 Armijo 准则，我们有

$$f(x^k) - f(x^{k+1}) \geq c_1\alpha_k(-\nabla f(x^k)^\top d^k) \geq c_1\alpha\sigma > 0.$$

因为 $f(x^k)$ 收敛到有限值 $\bar{f}$，当 $k \to \infty$ 时，必然有 $f(x^k) - f(x^{k+1}) \to 0$. 但这与上面的式子严格大于一个正常数 $c_1\alpha\sigma$ 发生了矛盾！

综上所述，我们的假设不成立，序列的每一个极限点都必定是目标函数的稳定点。 □

在实际的算法运行中，我们注意到生成的迭代序列始终被限制在初始点所在的下水平集中：

$$\{x^k\} \subseteq \{x \in \mathbb{R}^n : f(x) \leq f(x^0)\}.$$

显然，选取的初值不同，算法最终落入的稳定点可能会有所不同；但在确定性算法中，对于同一个初值，其落入的稳定点必然是相同的。进一步地，如果该下水平集 $\{x \in \mathbb{R}^n : f(x) \leq f(x^0)\}$ 是有界的，结合连续函数的性质，我们立刻可以得到一个更强的结论：此时梯度序列的范数必然趋于零，即

$$\lim_{k\to\infty} \|\nabla f(x^k)\| = 0.$$

证明. 假设结论不成立，则存在 $\varepsilon > 0$ 和子列 $\{x^{m_k}\}$，使得

$$\|\nabla f(x^{m_k})\| \geq \varepsilon > 0, \quad \forall k \in \mathbb{N}.$$

由于下水平集是有界闭集，根据 Bolzano–Weierstrass 定理，必定存在一个收敛子列 $\{x^{m_{k_j}}\}$，使得 $x^{m_{k_j}} \to \bar{x}$. 由定理 0.2 可知，$\bar{x}$ 是一个稳定点，因此

$$\nabla f(\bar{x}) = 0 < \varepsilon,$$

这与我们之前的假设产生了矛盾！因此，梯度范数必然趋于零。 □

那么，在不使用线搜索准则的情况下，预设步长策略又该如何选择呢？我们有以下考量：

1. 常数步长：在缺乏全局信息时，一个固定的常数步长几乎不可能在整个迭代过程中始终保证函数值的下降。

2. 递减步长：为了保证全局收敛，步长往往需要满足 $\sum_{k=1}^{+\infty} \alpha_k = +\infty$ （确保衰减不能太快，以到达空间中任意远的极值点）以及 $\sum_{k=1}^{+\infty} \alpha_k^2 < +\infty$ （确保衰减不能太慢，以抑制收敛过程中的震荡现象）。由此可得，一个典型的理论选择是 $\alpha_k = \frac{1}{k}$.

在实践中，一种可能的混合策略是：前几步采用常数步长进行快速探索，而在后面阶段采用递减步长以保证收敛。但必须指出，这种先验设定的策略依然无法彻底解决某些病态问题中不收敛的困境。

为了对算法进行更精细的定量分析，我们通常需要引入额外的平滑性条件。我们假设目标函数的梯度 $\nabla f(x)$ 满足 Lipschitz 连续性条件，也就是说，存在常数 $L > 0$，使得对于空间中的任意 x, y，都有

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|.$$

在引入了 Lipschitz 连续的梯度后，我们能得到什么好性质呢？以下引理给出了目标函数的一个极其重要的二次上界：

0.3 引理

假设 f 的梯度是 L-Lipschitz 连续的，则对于任意的 x, y，有如下不等式成立：

$$f(y) \leq f(x) + \langle \nabla f(x), y - x\rangle + \frac{L}{2}\|y - x\|^2. \tag{1}$$

利用上述引理中的不等式 (1)，我们来考察标准梯度下降法迭代步 $x^{k+1} = x^k - \alpha_k \nabla f(x^k)$ 的收敛性质。将 x^{k+1} 和 x^k 代入不等式中，我们有

$$f(x^{k+1}) - f(x^k) \leq \langle \nabla f(x^k), -\alpha_k \nabla f(x^k)\rangle + \frac{L}{2}\| - \alpha_k \nabla f(x^k)\|^2.$$

提取公共项并化简，我们立刻得到

$$f(x^{k+1}) - f(x^k) \leq -\alpha_k \left(1 - \frac{L}{2}\alpha_k\right) \|\nabla f(x^k)\|^2.$$

为了保证函数值严格下降，我们需要让上式右侧为负，即 $1 - \frac{L}{2}\alpha_k > 0$。由此解得步长的理论安全区间为 $0 < \alpha_k < \frac{2}{L}$. 在实际分析中，我们常取参数 $\alpha_k = \frac{1}{L}$，这正是梯度下降法在平滑条件下的标准常数步长选择。

这段推导极为直观地告诉我们：Lipschitz 常数 L 实际上衡量了空间中梯度的最大变化率，对应着函数局部曲率的上限。当我们处于高曲率区域（即 L 很大）时，必须迈出极为谨慎的小步子，避免步子过大越过极小值区域，导致函数值不降反升。

尽管常数步长 $\alpha_k = \frac{1}{L}$ 在理论上非常优美，但在应用层面却面临着严峻的问题：

1. 全局的 Lipschitz 常数 L 往往难以精确估计。
2. 事实上，我们根本无需全局的 L 信息，只要能估计当前点局部的曲率特性就足够了。一种行之有效的局部估计方法便是利用 (1) 式进行回溯线搜索。

那么，梯度下降法中这一步迭代背后的深层代数特征又是什么呢？我们将迭代公式重写如下：

$$x^{k+1} = x^k - \alpha \nabla f(x^k).$$

不难发现，这个迭代格式完全等价于求解如下的极小化问题：

$$x^{k+1} = \arg\min_x \left\{ f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2\alpha}\|x - x^k\|^2 \right\}.$$

注意到，上式中二次惩罚项的系数 $\frac{1}{\alpha}$，其作用本质上正是在模拟并估计局部的二阶 Hessian 矩阵信息。

因此，我们可以得出一个启发性的结论：梯度方法本质上是在当前迭代点周围进行的一个粗糙的二次优化。这就引出了优化领域中一个经典的权衡：如果我们构造的局部模型逼近得越好，单步子问题的求解就越困难；反之，如果逼近得越差，单步计算虽然简单，但总体达到收敛所需的迭代步数就会显著增加。

最后，我们来补齐前文留下的逻辑缺口，对引理中的重要不等式 (1) 给出严格的证明：

Proof of (1). 我们利用参数化线段的思想，构造一维辅助函数 $g(t) = f(x + t(y - x))$，其中 $t \in [0, 1]$. 根据微积分基本定理，我们有

$$g(1) - g(0) = \int_0^1 g'(t)\,\mathrm{d}t.$$

将 $g(t)$ 的定义代入等式左右两侧，即等价于

$$f(y) - f(x) = \int_0^1 g'(t)\,\mathrm{d}t.$$

利用多元函数的链式法则，我们计算 $g(t)$ 的导数为

$$g'(t) = \langle \nabla f(x + t(y - x)), y - x \rangle.$$

为了利用梯度的 Lipschitz 条件，我们在内积中巧妙地加减一项 $\nabla f(x)$，将其拆分为两部分：

$$g'(t) = \langle \nabla f(x + t(y - x)) - \nabla f(x), y - x \rangle + \langle \nabla f(x), y - x \rangle.$$

我们将这个展开后的导数表达式代回前面的积分公式中，整理可得

$$f(y) - f(x) = \langle \nabla f(x), y - x \rangle + \int_0^1 \langle \nabla f(x + t(y - x)) - \nabla f(x), y - x \rangle\,\mathrm{d}t.$$

接着，利用 Cauchy-Schwarz 不等式，我们将积分项内部放缩为范数的乘积：

$$f(y) - f(x) \le \langle \nabla f(x), y - x \rangle + \int_0^1 \|\nabla f(x + t(y - x)) - \nabla f(x)\| \cdot \|y - x\|\,\mathrm{d}t.$$

此时，我们终于可以利用梯度满足 L-Lipschitz 连续这一前提，将积分内部的梯度差项进一步放缩：

$$f(y) - f(x) \le \langle \nabla f(x), y - x \rangle + \int_0^1 L\|t(y - x)\| \cdot \|y - x\|\,\mathrm{d}t.$$

把标量 t 提取出来，并合并向量范数，我们有

$$f(y) - f(x) \leq \langle \nabla f(x), y - x \rangle + \int_0^1 tL\|y - x\|^2 \,\mathrm{d}t.$$

最后，只需计算关于 t 的定积分 $\int_0^1 t \,\mathrm{d}t = \frac{1}{2}$，便自然而然地推导出了我们想要的优美结论：

$$f(y) - f(x) \leq \langle \nabla f(x), y - x \rangle + \frac{L}{2}\|y - x\|^2.$$

至此，证明完毕。 $\square$