MATH20008h.01 最优化方法 (H) Spring 2026

Lecture 5 梯度算法收敛性、随机梯度 — 2026.04.03

Lecturer: 郦旭东

Scribe: 路人甲

目录

1 衰减步长梯度下降 **1**

2 随机梯度方法 **4**

1 衰减步长梯度下降

在上节课我们提到，采用常数步长和衰减步长的梯度下降算法通常需要有一定的连续性假设才能保证收敛性。通常，我们会假设梯度 Lipschitz 连续，即

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|.$$

Lipschitz 连续有一个著名的结论，叫下降引理，即

$$f(x) \leq f(y) + \langle \nabla f(y), x - y\rangle + \frac{L}{2}\|x - y\|_2^2.$$

根据下降引理，对最速下降法，我们有

$$f(x^{k+1}) - f(x^k) \leq -\alpha_k\|\nabla f(x^k)\|_2^2 + \frac{L}{2}\alpha_k^2\|\nabla f(x^k)\|_2^2 = -\alpha_k\left(1 - \frac{L}{2}\alpha_k\right)\|\nabla f(x^k)\|_2^2.$$

因此，为确保算法能够有效下降，我们需要保证 $\alpha_k \in (0, 2/L)$. 如果我们采用常数步长策略，我们常常会取 $\alpha_k = 1/L$. 若 $\alpha_k \leq \frac{1}{L}$，我们有

$$f(x^{k+1}) - f(x^k) \leq -\frac{1}{2}\alpha_k\|\nabla f(x^k)\|_2^2.$$

现在，我们来考虑衰减步长的最速下降法。我们通常会要求 $0 \leq \alpha_k \leq \frac{1}{L}$. 我们有如下定理：

1.1 定理

若目标函数 f 有下界，且梯度是 L-Lipschitz 连续的，考虑带衰减步长的最速下降法，设产生的迭代点列为 $\{x^k\}$，则有

$$\sum_{k=0}^{\infty} \alpha_k \|\nabla f(x^k)\|^2 < +\infty.$$

证明. 我们考虑构造可裂项相消的序列（telescope sequence）。由于 $\alpha_k \in [0, 1/L]$，我们有

$$f(x^{k+1}) - f(x^k) \leq -\frac{\alpha_k}{2} \|\nabla f(x^k)\|_2^2.$$

仔细观察上式：右端求和过后正是我们的目标级数，而左端是一个可以裂项相消的序列，因此

$$\sum_{k=0}^{+\infty} \alpha_k \|\nabla f(x^k)\|_2^2 \leq -2 \sum_{k=0}^{+\infty} [f(x^{k+1}) - f(x^k)].$$

由于 f 有下界，因此右端必定有界，这就证明了我们想要的结论。 □

事实上，对于一般的一阶算法，设下降方向为 d^k，定义下降方向与负梯度方向的夹角 θ_k 满足

$$\cos\theta_k = \frac{-\langle \nabla f(x^k), d^k \rangle}{\|\nabla f(x^k)\|_2 \|d^k\|_2}.$$

如果我们采用 Armijo–Wolfe 线搜索，我们有如下结论：

$$\sum_{k=0}^{\infty} \cos\theta_k \|\nabla f(x^k)\|_2^2 < \infty.$$

定理 1.1 的假设是相当弱的，对目标函数也没有太多的要求：如果目标函数连一个下界都找不到，那么这个优化问题本身也没有意义；连续性假设更是许多收敛性证明的基石。在实践中，以上条件往往都会满足。因此，我们的假设并不过分。它的结论似乎看起来比较弱，没有给出任何收敛性保证；但倘若我们让 $\sum_{k=0}^{+\infty} \alpha_k = +\infty$，我们就有

$$\liminf_{k\to\infty} \|\nabla f(x^k)\|_2 = 0.$$

这个结论可以用反证法来说明。假使上述极限大于零，那么对于充分大的 k，$\|\nabla f(x^k)\|_2$ 有一个下界 $\delta > 0$，从而

$$\sum_{k>K} \alpha_k \|\nabla f(x^k)\|_2^2 \geq \delta \sum_{k>K} \alpha_k = +\infty.$$

这与定理 1.1 是矛盾的。虽然梯度范数的下极限趋于零这个结论本身也不够强，但反之，假如我们假设 $\sum_{k=0}^{+\infty} \alpha_k < +\infty$，定理 1.1 的结论将没有任何意义：我们只需要梯度范数有界即可，这给不了我们任何收敛性保证。

假如我们进一步要求目标函数是凸函数，结论将会更强：

1.2 推论

设目标函数 f 是凸函数，且有下界。它的梯度是有界的。考虑带步长衰减的最速下降法，若步长满足

$$\sum_{k=0}^{+\infty} \alpha_k^2 < \infty,$$

设迭代点列为 $\{x^k\}_{k\in\mathbb{N}}$，且 $\|x^0 - x^*\|$ 有界，则

$$\sum_{k=0}^{+\infty} \alpha_k (f(x^k) - f(x^*)) < \infty.$$

证明. 我们考虑构造裂项相消序列。考虑

$$\begin{aligned}
\|x^{k+1} - x^*\|_2^2 &= \|x^k - \alpha_k \nabla f(x^k) - x^*\|_2^2 \\
&= \|x^k - x^*\|_2^2 - 2\alpha_k \langle \nabla f(x^k), x^k - x^* \rangle + \alpha_k^2 \|\nabla f(x^k)\|_2^2 \\
&\le \|x^k - x^*\|_2^2 - 2\alpha_k (f(x^k) - f(x^*)) + \alpha_k^2 \|\nabla f(x^k)\|_2^2.
\end{aligned}$$

其中最后一个不等号利用了如下不等式：

$$f(x^k) - f(x^*) \le \langle \nabla f(x^k), x^k - x^* \rangle.$$

因此

$$2\alpha_k (f(x^k) - f(x^*)) \le \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2 + \alpha_k^2 \|\nabla f(x^k)\|_2^2.$$

由于 $\|\nabla f(x^k)\|_2^2$ 有界，且 $\sum_{k=0}^{\infty} \alpha_k^2 < \infty$，我们立即有

$$\sum_{k=0}^{\infty} \alpha_k (f(x^k) - f(x^*)) < \infty.$$

□

我们知道

$$\sum_{k=0}^{N} (\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2) = \|x^0 - x^*\|_2^2 - \|x^{N+1} - x^*\|_2^2 \le \|x^0 - x^*\|_2^2,$$

因此由极限保号性

$$\sum_{k=0}^{\infty} (\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2) \le \|x^0 - x^*\|_2^2.$$

这是我们放缩前面裂项级数的思路。但算法在无穷远处，$\|x^N - x^*\|_2^2$ 有可能会很大，这样上面裂项级数有可能会发散到负无穷。但是，事情并没有想象中那么坏：假使它发散到负无穷，$\sum_{k=0}^{\infty} \alpha_k (f(x^k) -$

$f(x^*))$ 受它所控制，必然也会发散到负无穷；可是这个级数是非负的，因此序列 $\|x^N - x^*\|_2^2$ 是有上界的。

此外，由推论 1.2 我们还知道：

$$\liminf_{k\to\infty}(f(x^k) - f(x^*)) = 0.$$

这里的分析和前面是类似的，故略去不谈。

如前所述，在使用衰减步长机制时，我们常常会要求步长满足：

1. $\sum_{k=0}^{\infty} \alpha_k = \infty$，即步长不能衰减过快；
2. $\sum_{k=0}^{\infty} \alpha_k^2 < \infty$，即步长不能衰减过慢。

定理 1.1 及推论 1.2 告诉我们，这两个条件并非凭空出现的。α_k 往往控制着与算法收敛性相关的函数值信息或梯度信息，如果 $\sum_{k=0}^{\infty} \alpha_k$ 收敛，那么我们将得不到任何收敛性保证；α_k^2 往往控制着噪声信息，如果 $\sum_{k=0}^{\infty} \alpha_k^2$ 发散，噪声项将不受控制地爆炸，同样使我们得不到收敛性保证。

2 随机梯度方法

在现代机器学习中，我们常常会面对一个未知的分布 P. 我们希望找到一个模型参数 x，使得它在真实世界的表现最好。从数学上讲，我们希望将期望风险最小化，即

$$\min_{x\in\mathbb{R}^n} R(x) = \mathbb{E}_{z\sim P}\ell(x; z).$$

其中 $z \sim P$ 是从真实分布中抽取的一个数据点，$\ell(x; z)$ 是模型在这个点的损失。但问题是，我们并不知道真实分布 P 长什么样，期望是无法计算的。我们只能获得从 P 中独立同分布采样出来的 m 个样本 $z_1, z_2, \ldots, z_m$. 因此我们不妨考虑用这些样本损失的平均值来近似替代期望。在实际问题中，我们做的优化往往具有如下有限和形式：

$$\min_{x\in\mathbb{R}^n} \frac{1}{m}\sum_{i=1}^{m} f_i(x), \quad m \gtrsim n.$$

如果我们用精确的梯度下降算法去解这个优化问题，代价将让人难以承受：计算全梯度需要遍历整个数据集，在 ImageNet （120 万张图）上，走一步就要等好几天，这在工程上是不能接受的。那么，如果我们不使用最速下降法，选用一些近似的下降方向和线搜索，这样可行吗？答案是不可行。线搜索需要许多次函数值评估，但有时函数值的计算也不便宜：算全函数值必须跑完全部的 m 个样本的前向传播并累加，这在工程上同样让人难以接受。这两个“贵”加在一起，迫使深度学习领域独立发展出了一套几乎完全依赖随机梯度、不依赖全函数值评估的优化方法论。

2.1 定义 随机梯度

随机梯度 $g(x,\xi)$ 是全梯度 $\nabla f(x)$ 的无偏估计，即 $\mathbb{E}g(x,\xi)=\nabla f(x)$.

注：随机梯度建立在无偏估计之上；但现实中有一些问题是没办法建立无偏估计的，因此需要一些更高级的手段来纠正偏差。

通常，我们会对随机梯度作如下假设。

2.2 假设

1. 无偏估计：$\mathbb{E}[g(x;\xi)]=\nabla f(x)$.
2. 二阶矩有限：$\mathbb{E}[\|g^k\|^2]\le M+M\|\nabla f(x^k)\|^2$, $\exists M>0$.
3. 目标函数有下界，梯度 L-Lipschitz 连续。

所谓的随机梯度算法，大体遵从如下框架：

Algorithm 1: 随机梯度下降法

Input: 初始点 x^0

Output: 近似最优解 x^N

```
while ‖∇f(x^k)‖ < ε do
    Randomly pick i* ∈ {1, 2, ..., m}.
    g(x^k; ξ^k) = ∇f_{i*}(x^k)
    x^{k+1} = x^k − α_k g(x^k, ξ^k)
end
return x_N.
```

在算法 1 中我们选取了其中一个函数的梯度作为真实梯度的近似；但实际上我们常常还会用另一种近似方法： mini-batch GD，即随机抽取 p 个样本，计算这 p 个样本损失函数的梯度，取平均值作为真实梯度的估计。后者会比前者更准确一些。

那么，随机梯度法的收敛性如何呢？仿照定理 1.1，我们有如下结论：

2.3 定理

在假设 2.2 及算法 1 下，若 $\alpha_k \le \frac{1}{LM}$，且

$$\sum_{k=0}^{\infty} \alpha_k^2 < \infty,$$

我们有

$$\sum_{k=0}^{+\infty} \alpha_k \mathbb{E}\|\nabla f(x^k)\|^2 < +\infty.$$

证明. 由下降引理，我们有

$$f(x^{k+1}) \le f(x^k) - \alpha_k \langle \nabla f(x^k), g^k \rangle + \frac{L}{2}\alpha_k^2 \|g^k\|^2.$$

两边取条件期望 $\mathbb{E}[\cdot \mid x^k]$，有

$$\mathbb{E}[f(x^{k+1}) - f(x^k) \mid x^k] \le -\alpha_k \|\nabla f(x^k)\|^2 + \frac{L}{2}\alpha_k^2 \mathbb{E}[\|g^k\|^2 \mid x^k].$$

由于 $\mathbb{E}[\|g^k\|^2 \mid x^k] \le M + M\|\nabla f(x^k)\|^2$，我们有

$$\alpha_k \|\nabla f(x^k)\|^2 \le \mathbb{E}[f(x^{k+1}) - f(x^k) \mid x^k] + \frac{L}{2}\alpha_k^2 (M + M\|\nabla f(x^k)\|^2).$$

亦即

$$\alpha_k \left(1 - \frac{LM}{2}\alpha_k\right) \|\nabla f(x^k)\|^2 \le \mathbb{E}[f(x^k) - f(x^{k+1}) \mid x^k] + \frac{L}{2}\alpha_k^2 M.$$

两边取全期望，有

$$\alpha_k \left(1 - \frac{LM}{2}\alpha_k\right) \mathbb{E}\|\nabla f(x^k)\|^2 \le \mathbb{E}[f(x^k) - f(x^{k+1})] + \frac{LM}{2}\alpha_k^2$$

由 $\alpha_k < \frac{1}{LM}$，我们有 $1 - \frac{LM}{2}\alpha_k \ge \frac{1}{2}$，再结合 $\sum_{k=0}^{+\infty} \alpha_k^2 < \infty$，因此我们有

$$\sum_{k=0}^{\infty} \alpha_k \mathbb{E}\|\nabla f(x^k)\|^2 < \infty.$$

□

同样地，如果 $\sum_{k=0}^{\infty} \alpha_k = +\infty$，我们有

$$\liminf_{k\to\infty} \mathbb{E}\|\nabla f(x^k)\|^2 = 0.$$