MATH20008h.01 最优化方法 (H) Spring 2026

Lecture 6 梯度算法收敛速度及加速 — 2026.04.03

Lecturer: 郦旭东

Scribe: 路人甲

目录

1 梯度算法收敛速度 **1**

2 Nesterov 加速 **6**

1 梯度算法收敛速度

衡量一个算法的质量，不单单包括其收敛性，还包括其收敛速度。例如，最速下降法具有全局收敛性，但在一些病态问题上收敛较慢；牛顿法并没有全局收敛性，但它在局部具有二次收敛速度。因此，分析算法的收敛速度是非常重要的，有时通过分析收敛速度，我们甚至还能借此设计出更好的算法（详见数值二 Lecture 1）。

常见的收敛速度包括：

1. 线性收敛。这指的是 $\frac{\|x^{k+1}-x^*\|}{\|x^k-x^*\|} \le q$，其中 $q<1$ 是一个常数。这等价于 $\|x^k-x^*\| \le Cq^k$. 那么，为什么这样子的收敛叫线性收敛呢？假设 $q=1/2$，那么在二进制下，误差每次迭代都会减少一位，相当于 x^k 的有效数字每次迭代增加一位。对于一般的 q，我们也可以理解为在某种进制意义下有效数字会线性增加，因此称为线性收敛。

2. 超线性收敛。这指的是
$$\lim_{k\to\infty} \frac{\|x^{k+1}-x^*\|}{\|x^k-x^*\|} = 0.$$
这意味着误差的减少速度比线性更快。例如，假如
$$\lim_{k\to\infty} \frac{\|x^{k+1}-x^*\|}{\|x^k-x^*\|^2} = C,$$
其中 $C>0$ 是一个常数，那么我们就说 x^k 以二次收敛的速度收敛到 x^*. 二次收敛意味着有效数字会随着迭代次数的增加而成倍增加，因此称为二次收敛。下面是二次收敛的一个例子：$x_{n+1}=\frac{1}{2}(x_n+2/x_n)$ 具有全局线性收敛性和局部二次收敛性。如果我们设定初值 $x_0=1$，那么序列的前 8 项是：

1

1.5

1.416666666666666666666666666666666666666666666666666666666675

1.41421568627450980392156862745098039215686274509803921568627 45

1.4142135623746899106262955788901349101165596221157440445849057

1.41421356237309504880168962350253024361498192577619742849828 90

1.414213562373095048801688724209698078569671875372340015610125

1.41421356237309504880168872420969807856967187537694807317667 96

其中加粗部分表示有效数字。显然，有效数字是成倍增长的。

接下来，我们来看看梯度算法的收敛速度。我们从最简单的最速下降法开始。

1.1 定理

考虑二次函数 $q(x) = \frac{1}{2}\langle x, Qx\rangle$，其中 $Q = Q^\top \succ 0$. 设 Q 的特征值按从小到大顺序排列为 $\lambda_1 \le \lambda_2 \le \cdots \le \lambda_n$，则记 Q 的条件数为 $\kappa = \lambda_n/\lambda_1$. 带常数步长 $t_k = \arg\min_{t>0} q(x^k - t\nabla q(x^k))$ 的最速下降法在 q 上的收敛速度为

$$\frac{q(x^{k+1})}{q(x^k)} = 1 - O\left(\frac{1}{\kappa}\right).$$

证明. $q(x)$ 的梯度为

$$\nabla q(x) = Qx.$$

因此，最速下降法的步长满足

$$\langle Q(x^k - t_k Qx^k), Qx^k\rangle = 0.$$

如果我们记 $d^k = Qx^k$，那么

$$t_k = \frac{\langle d^k, d^k\rangle}{\langle d^k, Qd^k\rangle}.$$

因此

$$\begin{aligned}
q(x^{k+1}) &= q(x^k - t_k d^k) \\
&= \frac{1}{2}\langle x^k - t_k d^k, Q(x^k - t_k d^k)\rangle \\
&= \frac{1}{2}\langle x^k, Qx^k\rangle - t_k\langle d^k, d^k\rangle + \frac{1}{2}t_k^2\langle d^k, Qd^k\rangle \\
&= q(x^k) - \frac{1}{2}\frac{\langle d^k, d^k\rangle^2}{\langle d^k, Qd^k\rangle}
\end{aligned}$$

因此，

$$\begin{aligned}\frac{q(x^{k+1})}{q(x^k)} &= 1 - \frac{\langle d^k, d^k\rangle^2}{\langle d^k, Qd^k\rangle \cdot \langle d^k, Q^{-1}d^k\rangle} \\ &\le 1 - \frac{1}{\kappa}.\end{aligned}$$

其中最后一个不等号利用了 Rayleigh 商的性质：$\lambda_1 \le R(Q,x) \le \lambda_n$. 这是一个比较粗的放缩。更精细的放缩可以做到

$$\frac{q(x^{k+1})}{q(x^k)} \le 1 - \frac{4}{\kappa}.$$

这需要一些额外的不等式，我们这里不作介绍。不论哪种方式，我们得到的结论都是 $1 - O(1/\kappa)$.

□

在一些病态问题上，条件数 κ 可能非常大，例如最大特征值 10^4，而最小特征值 1，条件数 κ 就达到了 10^4，线性收敛的速度就非常慢了。我们知道，求解二次规划最好的方法是共轭梯度法。共轭梯度法在二次函数上同样是线性收敛，但常数是 $1 - O(1/\sqrt{\kappa})$. 如果条件数是 $\kappa = 10^4$，最速下降法的线性收敛因子是 0.9999，而共轭梯度法的线性收敛因子是 0.99，收敛就会快得多。

以上是梯度算法在二次函数上的收敛速度。那么在更一般的函数上，梯度算法会有怎样的表现呢？我们先来看一类特殊的函数：强凸函数。

1.2 定义 强凸函数

若函数 $f(x)$ 满足

$$f(y) \ge f(x) + \langle \nabla f(x), y - x\rangle + \frac{\mu}{2}\|y - x\|_2^2,$$

则称 f 是强凸的。

直观地看来，$f(x) + \langle \nabla f(x), y - x\rangle$ 是过点 $(x, f(x))$ 的切线，一般的凸函数只满足图象比切线要高，它可以平坦得像一条直线。但强凸函数不同，它要比一个二次函数来得高，不可能如直线一般平坦，它在图象上必须是又尖又圆的。

强凸性不仅仅关联了函数值和点列，还将二者与梯度信息关联起来：

1.3 引理 *Polyak–Lojasiewicz* 条件

若目标函数 f 是 μ-强凸的，则有

$$\|\nabla f(x)\|_2^2 \ge 2\mu(f(x) - f(y)), \quad \forall x, y \in \mathbb{R}^n.$$

这个不等式我们称之为 Polyak–Lojasiewicz 条件，简称为 PL 条件。反之，如果我们有 PL 条件，我们并不能推断 f 是强凸函数——事实上，很多非凸目标函数也是满足 PL 条件的。

证明. 由强凸性，有

$$f(y) - f(x) \geq \langle \nabla f(x), y - x \rangle + \frac{\mu}{2}\|y - x\|_2^2.$$

两边乘上 -1，不等式变号：

$$f(x) - f(y) \leq \langle \nabla f(x), x - y \rangle - \frac{\mu}{2}\|y - x\|_2^2.$$

由 Cauchy–Schwarz 不等式，内积项可以放大为范数乘积，即

$$f(x) - f(y) \leq \|\nabla f(x)\|_2 \cdot \|x - y\|_2 - \frac{\mu}{2}\|x - y\|_2^2.$$

注意到右边是关于 $\|x - y\|_2$ 的开口向下的二次函数，我们可以将其放大至最大值，有

$$f(x) - f(y) \leq \frac{1}{2\mu}\|\nabla f(x)\|_2^2,$$

即

$$\|\nabla f(x)\|_2^2 \geq 2\mu(f(x) - f(y)), \quad \forall x, y \in \mathbb{R}^n.$$

□

如果我们取 $y = x^*$，那么结论就是

$$\|\nabla f(x)\|_2^2 \geq 2\mu(f(x) - f^*).$$

注意到强凸性本身也能带来函数值信息和点列信息之间的联系：

$$f(x) - f^* \geq \frac{\mu}{2}\|x - x^*\|_2^2.$$

因此

$$\|\nabla f(x)\|_2^2 \geq \mu^2\|x - x^*\|_2^2.$$

需要注意的是，在介绍梯度 Lipschitz 连续时我们介绍了一个下降引理：

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2}\|y - x\|_2^2.$$

请注意符号的差别：由 Lipschitz 连续推导出的下降引理是小于等于号，而强凸性的定义是大于等于号。这也并不难理解： Lipschitz 连续要求梯度受点的距离线性控制，这势必导致目标函数的增长不会超过二次函数，出现一个小于等于号不足为奇。如果一个函数既是强凸的，又是梯度 Lipschitz 连续的，那么它就应该被两个二次函数夹住，只能在这两个抛物面的缝隙之间蜿蜒。这意味着目标函数不会下降得太快（梯度不 Lipschitz 连续），以至于算法一下子就飞出去；也不会下降得太慢（不强凸），以至于算法慢悠悠地磨蹭。从几何直观上来讲，梯度算法在这样的函数上应该有着良好的表现。从代数直观来看，强凸性如上所述，满足不等式

$$\|\nabla f(x)\|_2^2 \geq 2\mu(f(x) - f^*) \geq \mu^2\|x - x^*\|_2^2.$$

而梯度 L-Lipschitz 则提供了另一个方向的不等式，最终我们一定有

$$\|\nabla f(x)\|_2^2 = \Theta(f(x) - f^*) = \Theta(\|x - x^*\|_2^2),$$

这意味着我们只要控制任意一个量，剩下两个量都会以同阶的速度被控制住。这是一个非常强的结论：我们之前证明的收敛性大多只关注其中一个量（往往是梯度），剩下两个量往往很难控制住。

无论如何，我们有如下定理：

1.4 定理

假设 f 是 μ-强凸的，梯度是 L-Lipschitz 连续的。考虑带常数步长的最速下降法

$$x^{k+1} = x^k - \frac{1}{L}\nabla f(x^k),$$

则有

$$f(x^k) - f^* \leq \left(1 - \frac{1}{L/\mu}\right)^k \cdot (f(x^0) - f^*).$$

注

1. 为什么常数步长选用 $1/L$？这是因为

$$x^{k+1} = \arg\min_x \{f(x^k) + \langle \nabla f(x^k), x - x_k\rangle + \frac{L}{2}\|x - x_k\|_2^2\}.$$

   优化函数正是下降引理的右端项。化简后即得

$$x^{k+1} = x^k - \frac{1}{L}\nabla f(x^k).$$

2. 这是线性收敛的结果。对比上面二次函数线性收敛的系数 $1 - 1/\kappa$，我们常常称 $\kappa = L/\mu$ 为该优化问题的条件数。

证明. 考虑

$$\begin{aligned}
f(x^{k+1}) - f^* &= f(x^{k+1}) - f(x^k) + f(x^k) - f^* \\
&\leq \langle \nabla f(x^k), x^{k+1} - x^k\rangle + \frac{L}{2}\|x^{k+1} - x^k\|_2^2 + f(x^k) - f^* \\
&= f(x^k) - f^* - \frac{1}{2L}\|\nabla f(x^k)\|_2^2 \\
&\leq f(x^k) - f^* - \frac{1}{2L} \cdot 2\mu(f(x^k) - f^*) \\
&= \left(1 - \frac{1}{L/\mu}\right)(f(x^k) - f^*).
\end{aligned}$$

其中第一个不等式利用了下降引理，第二个不等式利用了引理 1.3. 于是我们显然有

$$f(x^k) - f^* \le \left(1 - \frac{1}{L/\mu}\right)^k (f(x^0) - f^*).$$

□

这个定理雄辩地证明：强凸函数若梯度 Lipschitz 连续，在梯度算法眼里，它和二次函数并没有本质区别。

2 Nesterov 加速

既然二次函数可以用共轭梯度法来加速，那么对于梯度 Lipschitz 连续的强凸函数，我们是否有办法加速呢？

苏联人 Nesterov 提出了如下加速。

Algorithm 1: Nesterov Accelerated Gradient, NAG

Input: 目标函数 f，初值 x^0. 正项序列 $\{t_k\}$，满足 $t_{k+1}^2 - t_{k+1} \le t_k^2$，其中 $t_0 = t_1 = 1$. 容差 ε.

Output: 近似最优解 x^N

while $\|\nabla f(x^k)\|_2 < \varepsilon$ **do**

  $\beta_k = \frac{t_k - 1}{t_{k+1}}$

  $\bar{x}^k = x^k + \beta_k(x^k - x^{k-1})$

  $x^{k+1} = \arg\min_x q(x, \bar{x}^k)$, where

$$q(x; \bar{x}) = f(\bar{x}) + \langle \nabla f(\bar{x}), x - \bar{x} \rangle + \frac{1}{2}\langle x - \bar{x}, H(x - \bar{x}) \rangle, \quad H \succeq 0.$$

end

return x^N

这个算法看起来很神秘，接下来我们来一步一步地拆解它。我们引入了一个“前瞻点列”$\{\bar{x}^k\}$，它由当前点 x^k 和动量 $x^k - x^{k-1}$ 线性组合而成。然后，我们利用这个前瞻点 $\bar{x}^k$ 的信息，得到下一个点 x^{k+1}：优化 $q(x; \bar{x})$. 请注意，梯度算法往往优化的是 $q(x; x^k)$，但这里我们使用的是 $\bar{x}$.

Nesterov 方法本质上是梯度法的改进，自然可以通过适当选取常数，得到梯度法。例如，假设 $t_k \equiv 1$，则有 $\beta_k \equiv 0$；再令 $H = LI$，其中 L 为 Lipschitz 常数，I 为单位阵——这就变成了梯度下降法。

那么，我们为什么要往前探一步呢？郦老师在课上的解释是：好比人开车，总是向前看；看到前面要转弯了，此刻便开始准备，并不会等到要转弯时再转弯。此外，还有一个解释是：梯度下降法在

比较病态的问题上会出现“锯齿”，导致收敛缓慢；如果我们每一步都加添加一些历史信息（所谓“动量”是也），使得每次转向都不要急转弯，收敛自然会快一些。我个人认为两种解释都是有道理的，但没有把本质说清楚；事实上这个算法的解释有非常多，得到 Nesterov 本人肯定的似乎就是“开车”之说（郦老师语）。

> *Nesterov 说他当年喝酒的时候想出来的这个加速。*
>
> —— lxd

在 NAG 之前，Nesterov 的老师 Polyak (即前面提到的 PL 条件的 P) 提出了重球法，也同样利用动量来加速收敛。它的迭代格式是

$$x^{k+1} = x^k - \alpha_k(\beta(x^k - x^{k-1}) + \nabla f(x^k)).$$

这个算法比 Nesterov 的算法好懂得多：每次都加入动量信息进行修正。和 Nesterov 最大的不同是，重球法采用了 x^k 的梯度，而非前瞻点的梯度。这也导致重球法比 NAG 来得慢。

在现代，有学者提出以 ODE 的视角来理解重球法和 Nesterov 加速。最早的工作可见于苏炜杰老师于 2015 年发表的论文 A Differential Equation for Modeling Nesterov's Accelerated Gradient Method: Theory and Insights. 具体地，我们可以把这些算法理解为 ODE 的离散化，即令 $x(t_k) = x^k$. 按照这个思路，我们可以将重球法和 NAG 连续地表示为

1. **重球法：**
$$\frac{\mathrm{d}^2 x}{\mathrm{d}t^2}(t) + \gamma \frac{\mathrm{d}x}{\mathrm{d}t}(t) + \nabla f(x(t)) = 0.$$
如果我们把 f 理解为势能，那么 $\nabla f(x(t))$ 就好比驱动力，而 $\gamma x'(t)$ 是一个正比于速度的项，就好比摩擦力。于是，整个式子可以理解为 Newton 定律的变形。

2. **Nesterov 加速：**
$$\frac{\mathrm{d}^2 x}{\mathrm{d}t^2}(t) + \frac{c}{t}\frac{\mathrm{d}x}{\mathrm{d}t}(t) + \nabla f(x(t)) = 0.$$
这里我们配给摩擦力一个随时间衰减的系数。这是更加自然的设计。

使用 ODE 的好处在于分析非常方便；但问题也不少：如果只是用其来辅助理解，不失为良策；但如果反过来用它来设计算法，会遇到一些问题。第一个问题是：Nesterov 已经证明他的算法达到了最优的阶，用 ODE 并不会得到更好的阶的算法，只能在常数上做一些改进。常数优化在工程上意义会更重大一些。第二个问题是：从连续到离散，如何确保连续的良好性质不会被破坏？我们是没办法给一个保证的，所以证明收敛性必须回到离散情形，用 ODE 提供一些洞见是可行的，但严格的数学证明必须在离散域上给出。

接下来，我们便来给出 Nesterov 加速的收敛速度。

2.1 定理

对于强凸问题，

- 梯度法：$f(x^k) - f^* = \mathcal{O}((1 - 1/\kappa)^k)$.
- NAG：$f(x^k) - f^* = \mathcal{O}((1 - 1/\sqrt{\kappa})^k)$.

对于一般凸问题，

- 梯度法：$f(x^k) - f^* = \mathcal{O}(1/k)$.
- NAG：$f(x^k) - f^* = \mathcal{O}(1/k^2)$.

可以发现，NAG 收敛速度显著地比标准梯度法快。

证明过于复杂，感兴趣的读者可以参考知乎相关文章，里面还提供了丰富的可视化。