MATH50009.01 数值算法与案例分析 II Spring 2026

Lecture 3 插值与拟合（二）— 2026.03.17

Instructor: 邵美悦

Scribe: 路人甲

目录

1 牛顿插值法 **1**

1.1 取样点的选择 4

1.2 Hermite 插值 7

2 基函数 **7**

3 样条插值 **8**

3.1 线性样条插值 8

3.2 三次 Hermite 插值 9

3.3 三次样条插值 9

3.3.1 定解条件 9

3.3.2 矩阵形式 10

1 牛顿插值法

给定 n 个不同的点 $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$，假如我们已经对前 $n-1$ 个数据点完成了拟合，得到一个多项式 $p_{n-1}(x)$，满足 $p_{n-1}(x_i) = y_i$；现在我们需要将第 n 个数据点 (x_n, y_n) 加入到拟合中，我们需要一个新的多项式 $p_n(x)$，满足 $p_n(x_i) = y_i \quad \forall i \in \{1, 2, \ldots, n\}$. 最简单的构造方法是将 $p_{n-1}(x)$ 加上一个修正项。这个修正项需要满足以下条件：

1. 当 $x = x_i \quad \forall i \in \{1, 2, \ldots, n-1\}$ 时，修正项为 0；
2. 当 $x = x_n$ 时，修正项要使得 $p_n(x_n) = y_n$.

显然我们可以设

$$p_n(x) = p_{n-1}(x) + a_n \prod_{i=1}^{n-1}(x - x_i),$$

其中 a_n 是一个待定系数。如果我们将 $x = x_n$ 代入上式，我们可以得到

$$y_n = p_{n-1}(x_n) + a_n \prod_{i=1}^{n-1}(x_n - x_i)$$

这说明

$$a_n = \frac{y_n - p_{n-1}(x_n)}{\prod_{i=1}^{n-1}(x_n - x_i)}.$$

由插值多项式的唯一性，结合 Lagrange 插值多项式，我们知道

$$a_n = \sum_{i=1}^{n} \prod_{j \neq i} \frac{y_i}{x_i - x_j}.$$

上面两个式子在数学上是完美的，但在实际数值计算中，计算复杂度都比较高。由于牛顿插值法本身是一个迭代法，我们可以考虑求出 a_n 的递推关系。我们先从一个简单的例子入手。假设我们有三个数据点 $(1,1),(2,2),(3,3)$，现在我们要求出 $(4,?)$ 中问号处的值。假设我们眼力不太好，小学老师曾经教过我们一种找规律的方法：拿后一项减去前一项，看看是否有规律。我们将因变量作差，得到 $1,1$——于是我们自然可以猜测下一个差也是 1. 然后，我们将 3 加上这个差 1，得到 4，这就是我们猜测的问号处的值。

再举一个例子，假设我们有四个数据点 $(1,1),(2,4),(3,9),(4,16)$，现在我们要求出 $(5,?)$ 中问号处的值。我们同样先作差，得到 $3,5,7$，假设我们眼力不大好，看不出什么规律，于是再次作差，得到 $2,2$. 这时我们就可以猜测下一个差也是 2，于是我们可以得到 $7+2=9$，然后再把这个 9 加上第四个数据点的因变量 16，得到 25，这就是我们猜测的问号处的值。

在上面的例子中，我们通过不断作差，最终推测出数据的规律。实际上，这种方法看似无厘头，实则有着深刻的数学原理。上面的方法可以概括为：通过不断作差，得到常数（列），然后在前面的基础上补上一个差值项，不断迭代，最终得到一个预测值。这种“在前面的基础上加修正”的思想与牛顿插值法不谋而合。实际上，这完全就是牛顿插值法的一个特例。一般地，假设我们的数据点

为 $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$，我们可以形成如下图所示的差商表：

$$
\begin{array}{cccccc}
x_1 & f(x_1) & & & & \\
 & & f[x_1, x_2] & & & \\
x_2 & f(x_2) & & f[x_1, x_2, x_3] & & \\
 & & f[x_2, x_3] & & \ddots & \\
\vdots & \vdots & & \vdots & & f[x_1, x_2, \ldots, x_n] \\
 & & \vdots & & \ddots & \\
x_{n-1} & f(x_{n-1}) & & f[x_{n-2}, x_{n-1}, x_n] & & \\
 & & f[x_{n-1}, x_n] & & & \\
x_n & f(x_n) & & & &
\end{array}
$$

如果我们从 $f(x_i)$ 出发，向右上角画一条斜线，那么斜线上的点就表示，加入 (x_i, y_i) 这个新的数据点之后需要额外计算的差商。根据我们前面的经验，某一个差商的计算可以通过它上一层的差商来计算，具体地

$$f[x_i, x_{i+1}, \ldots, x_j] = \frac{f[x_i, x_{i+1}, \ldots, x_{j-1}] - f[x_{i+1}, x_{i+2}, \ldots, x_j]}{x_i - x_j}.$$

因此，我们可以通过不断迭代，最终得到 $f[x_1, x_2, \ldots, x_n]$. 这是一个常数。假如新加入一个点 $(x_{n+1}, ?)$，我们需要预测这个问号处的值。我们需要一步步地补全差商表。最后一层只有一个常数 $f[x_1, x_2, \ldots, x_n]$，因此我们可以直接假设 $f[x_2, x_3, \ldots, x_{n+1}] = f[x_1, x_2, \ldots, x_n]$. 然后，我们利用迭代公式

$$f[x_i, x_{i+1}, \ldots, x_{n+1}] = \frac{f[x_i, x_{i+1}, \ldots, x_n] - f[x_{i+1}, \ldots, x_{n+1}]}{x_i - x_{n+1}}$$

得到

$$f[x_{i+1}, \ldots, x_{n+1}] = f[x_i, x_{i+1}, \ldots, x_n] + f[x_i, x_{i+1}, \ldots, x_{n+1}](x_{n+1} - x_i).$$

因此，我们可以通过不断上溯差商表，最终求出 $f(x_{n+1})$.

上述过程本质上构造了后向的牛顿插值多项式，经过轮换，我们可以得到前向的牛顿插值多项式

$$p_n(x) = p_{n-1}(x) + f[x_1, x_2, \ldots, x_n] \prod_{i=1}^{n-1} (x - x_i).$$

对比牛顿插值法的原始定义，我们知道

$$a_n = f[x_1, x_2, \ldots, x_n] = \frac{f[x_1, \ldots, x_{n-1}] - f[x_2, \ldots, x_n]}{x_1 - x_n}.$$

在实际计算中，我们往往会结合 DP 的思想，利用一个数组来存储差商表中的值，这样就可以避免重复计算，从而降低计算复杂度。

差商还有如下两条性质：

1. **对称性**：$f(\cdot)$ 在 $x_1, x_2, \ldots, x_k$ 处的 k 阶差商与点的顺序无关，即

$$f[x_1, x_2, \ldots, x_k] = f[\sigma(x_1), \sigma(x_2), \ldots, \sigma(x_k)], \quad \forall \sigma \in \mathfrak{S}_k.$$

2. **极限行为**：

$$\lim_{(x_1,\ldots,x_k)\to(x_*,x_*,\ldots,x_*)} f[x_1, x_2, \ldots, x_k] = \frac{f^{(k-1)}(x_*)}{(k-1)!}.$$

那么，用插值多项式来拟合数据的误差是什么呢？假设我们根据 $n-1$ 个数据点生成了一个插值多项式 $p_{n-1}(x)$，现在假设我们有一个新的数据点 (u, v)，我们不妨考虑新的插值多项式

$$p_n(x) = p_{n-1}(x) + f[x_1, x_2, \ldots, x_{n-1}, u] \prod_{i=1}^{n-1}(x - x_i).$$

我们知道，$p_n(u) = v$，于是用 $p_{n-1}(u)$ 拟合 v 的误差为

$$v - p_{n-1}(u) = p_n(u) - p_{n-1}(u) = f[x_1, x_2, \ldots, x_{n-1}, u] \prod_{i=1}^{n-1}(u - x_i).$$

更一般地

$$f(x) - p_{n-1}(x) = f[x_1, x_2, \ldots, x_{n-1}, x] \prod_{i=1}^{n-1}(x - x_i) = \frac{f^{(n)}(\xi)}{n!} \prod_{i=1}^{n-1}(x - x_i).$$

误差界为

$$|f(x) - p_{n-1}(x)| \le \frac{\sup_{t\in[a,b]} f^{(n)}(t)}{n!} \prod_{i=1}^{n-1} |x - x_i|$$

$$\|f(x) - p_{n-1}(x)\|_\infty \le \frac{\|f^{(n)}(x)\|_\infty}{n!} \left\| \prod_{i=1}^{n-1}(x - x_i) \right\|_\infty .$$

在理论上，$\frac{\|f^{(n)}(x)\|_\infty}{n!}$ 是我们无法改变的，但我们可以通过选择合适的插值节点来减小

$$\left\| \prod_{i=1}^{n-1}(x - x_i) \right\|_\infty .$$

假如我们等距采样，这一项可能会放得很大，误差可能就会很大，这就是 Runge 现象。在 3 月 10 日的作业中，我们用插值多项式拟合了 Runge 函数 $f(x) = (1 + 25x^2)^{-1}$ 在 $[-\pi, \pi]$ 上的值，其绝对误差如图 1 所示。可以发现，在区间的两端，误差非常大，这就是 Runge 现象的典型表现。

1.1 取样点的选择

我们现在希望找到一种取样方式，使得拟合误差尽可能地小。考虑

$$\min_{x_1,x_2,\ldots,x_n} \left\| \prod_{i=1}^{n}(x - x_i) \right\|_\infty .$$

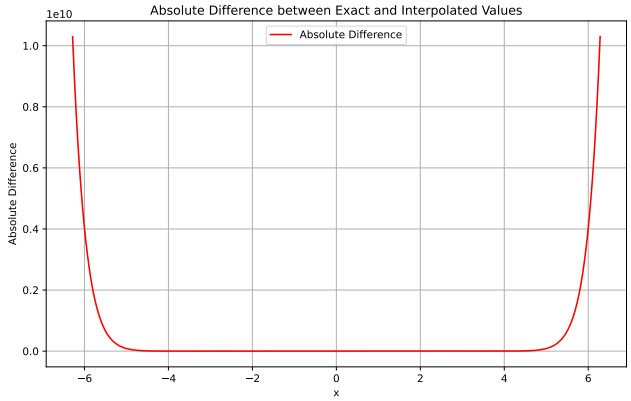

图 1: 多项式拟合 Runge 函数

我们可以把定义域平移放缩到 $[-1,1]$ 上，并将 $\prod_{i=1}^{n}(x-x_i)$ 视为放缩成 $f(x)\in[-1,1]$，现在我们只需求多项式 $f(x)$ 首项系数的最大值即可。事实上，我们可以证明，Chebyshev 多项式 $T_n(x)$ 的首项系数为 2^{n-1}，并且对于任意的定义域为 $[-1,1]$ 上的值域为 $[-1,1]$ 的 n 次多项式，其首项系数都不会超过 2^{n-1}. 下面我们给出 Chebyshev 多项式的定义以及相关性质。

1.1 定义 *Chebyshev* 多项式

我们称

$$T_n(x)=\cos(n\arccos x)$$

为 Chebyshev 多项式。

Chebyshev 多项式有着非常好的性质。

1.2 命题

Chebyshev 多项式 $T_n(x)$ 的递推公式为

$$T_{n-1}(x)+T_{n+1}(x)=2xT_n(x).$$

证明. 由积化和差公式得

$$2\cos(\arccos x)\cos(n\arccos x)=\cos((n+1)\arccos x)+\cos((n-1)\arccos x).$$

于是

$$T_{n-1}(x)+T_{n+1}(x)=2xT_n(x).$$

□

1.3 命题

Chebyshev 多项式的首项系数为 2^{n-1}.

证明. 由递推公式易证。 □

1.4 命题

Chebyshev 多项式的零点为 $x = \cos\frac{k\pi+\pi/2}{n}$，其中 $k = 0, 1, \ldots, n-1$.
Chebyshev 多项式的极值点为 $x = \cos\frac{k\pi}{n}$，其中 $k = 0, 1, \ldots, n$.

1.5 定理

定义于 $[-1, 1]$ 上的值域为 $[-1, 1]$ 的 n 次多项式的首项系数不超过 Chebyshev 多项式的首项系数，即 2^{n-1}.

证明. 用反证法。假设存在一个 n 次多项式 $p(x)$ 满足首项系数大于 2^{n-1}. 我们设

$$\alpha p(x) = 2^{n-1}x^n + q(x), \quad |\alpha| < 1.$$

而

$$T_n(x) = 2^{n-1}x^n + \tilde{q}(x).$$

两式作差，有

$$T_n(x) - \alpha p(x) = \hat{q}(x), \quad \deg \hat{q}(x) \le n-1.$$

取 $x = k\pi/n$，由于 $\alpha p(x) \in (-1, 1)$，而 $T_n(x) = \pm 1$，因此 $T_n(x) - \alpha p(x) \neq 0$.

由介值性，$\hat{q}(x)$ 在 $[-1, 1]$ 上有 n 个根。再由 $\deg \hat{q}(x) \le n-1$，于是 $\hat{q}(x) \equiv 0$，这与 $\hat{q}(k\pi/n) \neq 0$ 矛盾。证毕。 □

于是

$$\min_{x_1, x_2, \ldots, x_n \in [-1,1]} \left\| \prod_{i=1}^{n} (x - x_i) \right\|_\infty = 2^{1-n}.$$

而对于一般的区间 $[a, b]$，我们可以通过平移缩放将其转化为 $[-1, 1]$，因此

$$\min_{x_1, x_2, \ldots, x_n \in [a,b]} \left\| \prod_{i=1}^{n} (x - x_i) \right\|_\infty = 2^{1-n} \left(\frac{b-a}{2} \right)^n.$$

当且仅当 $x_i = \frac{a+b}{2} + \frac{b-a}{2}\cos\frac{(2i-1)\pi}{2n}$ 时达到最小值。这些节点被称为 Chebyshev 节点。假如我们选取 Chebyshev 节点进行插值，那么误差界为

$$\|f(x) - p_{n-1}(x)\|_\infty \le \frac{\left\|f^{(n)}(x)\right\|_\infty}{2^{n-1}n!} \left(\frac{b-a}{2} \right)^n.$$

1.2 Hermite 插值

有时我们不仅要对函数值本身进行拟合，我们还希望函数的导数值也能得到拟合。假设我们有 n 个数据点，我们希望找到一个多项式函数 $p(x)$ 满足

$$\begin{aligned}
p(x_1) &= f(x_1), & p'(x_1) &= f'(x_1), & \ldots, & & p^{(m_1)}(x_1) &= f^{(m_1)}(x_1), \\
p(x_2) &= f(x_2), & p'(x_2) &= f'(x_2), & \ldots, & & p^{(m_2)}(x_2) &= f^{(m_2)}(x_2), \\
&\vdots & &\vdots & \ddots & & &\vdots \\
p(x_n) &= f(x_n), & p'(x_n) &= f'(x_n), & \ldots, & & p^{(m_n)}(x_n) &= f^{(m_n)}(x_n).
\end{aligned}$$

这个问题同样可以用牛顿插值法解决。我们可以将每个数据点 x_i 重复 m_i+1 次，得到一个新的数据点序列

$$\underbrace{x_1, x_1, \ldots, x_1}_{m_1+1}, \underbrace{x_2, x_2, \ldots, x_2}_{m_2+1}, \ldots, \underbrace{x_n, x_n, \ldots, x_n}_{m_n+1}.$$

对这个序列，我们用牛顿插值法去拟合。对于重复的点，我们需要定义差商。我们定义

$$f\left[\underbrace{x_i, x_i, \ldots, x_i}_{k}\right] = \frac{f^{(k-1)}(x_i)}{(k-1)!}.$$

Hermite 插值的一种特殊情况是只有一个数据点 x_1. 这时的插值多项式就是 Taylor 多项式

$$f(x) = f(x_1) + f'(x_1)(x-x_1) + \cdots + \frac{f^{(m_1)}(x_1)}{m_1!}(x-x_1)^{m_1}.$$

2 基函数

之前我们介绍过，用待定系数法求解 $f(x) = a_{n-1}x^{n-1} + a_{n-2}x^{n-2} + \cdots + a_0$ 中的 a_i 的值，是非常不稳定的，原因是 Vandermonde 系统本身是一个病态系统。这种基于单项式基函数的方法避不开求解 Vandermonde 系统，因此非常不稳定。而 Lagrange 插值法和 Neville 插值法是基于 Lagrange 基函数发展的，牛顿插值法是基于牛顿基函数发展的，它们的数值稳定性都比较好。因此，选取合适的基函数对于插值问题是非常关键的。由于下面的样条插值会广泛地应用基函数的观点，我们先简单地介绍一下利用基函数进行插值的方法。

给定插值节点 $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n) \in \mathbb{R}^d \times \mathbb{R}$，我们考虑基函数 $\varphi_1, \varphi_2, \ldots, \varphi_n : \mathbb{R}^d \to \mathbb{R}$，使得插值多项式可以由基函数线性组合得到。根据插值条件，我们只需求解如下线性方程组

$$\begin{bmatrix} \varphi_1(x_1) & \varphi_2(x_1) & \cdots & \varphi_n(x_1) \\ \varphi_1(x_2) & \varphi_2(x_2) & \cdots & \varphi_n(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_1(x_n) & \varphi_2(x_n) & \cdots & \varphi_n(x_n) \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{bmatrix} = \begin{bmatrix} \varphi(x_1) \\ \varphi(x_2) \\ \vdots \\ \varphi(x_n) \end{bmatrix}$$

如果基函数的选择得当，那么上面的线性方程组就会是一个良态系统。例如，Lagrange 基函数 $\ell_i(x)$ 满足

$$\ell_i(x_j) = \delta_{i,j} = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

这就让系数矩阵变成了一个单位阵，因此数值稳定性非常好。牛顿基函数 $\varphi_k(x) = \prod_{i=1}^{k-1}(x - x_i)$ 也是一个非常好的基函数，因为它使得系数矩阵是一个下三角矩阵，因此数值稳定性也非常好。

常见的基函数还有分段三次基函数、有理函数、三角函数等。分段三次基函数我们会在下一小节介绍。其余基函数，限于篇幅，不作展开。

3 样条插值

前面的插值方法都是将插值多项式视为一个整体来构造的，但实际上我们还可以考虑构造分段函数来进行插值。

3.1 线性样条插值

最简单的样条插值方法是线性样条插值。给定 n 个数据点 $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$，我们可以直接将相邻的两个数据点用一条线段连接起来，这样就得到了一个分段线性函数。具体地，

$$s_i(x) = f(x_i) + \frac{f(x_{i+1}) - f(x_i)}{x_{i+1} - x_i}(x - x_i), \quad x \in [x_i, x_{i+1}].$$

这样构造出来的插值多项式是连续的，但不可导。它的误差界是

$$\|s(x) - f(x)\|_\infty \leq \frac{\|f''(x)\|_\infty}{8} h^2,$$

其中 $h = \max_{1 \leq i \leq n-1}(x_{i+1} - x_i)$ 是相邻数据点之间的最大距离。

证明. 在每个子区间 $[x_i, x_{i+1}]$ 上，我们相当于做了一次 Lagrange 插值，因此误差界为

$$\|f(x) - s_i(x)\|_\infty \leq \frac{\|f''(x)\|_\infty}{2!}(x - x_i)(x - x_{i+1}) \leq \frac{\|f''(x)\|_\infty}{8} h^2.$$

对所有的子区间取最大值，得到

$$\|s(x) - f(x)\|_\infty \leq \frac{\|f''(x)\|_\infty}{8} h^2.$$

□

线性样条插值虽然简单，但它的误差阶是 $O(h^2)$，而且不可导，因此很少在实际中使用。我们通常会使用三次插值方法。

3.2 三次 Hermite 插值

假如函数的在每个采样点的一阶导数值已知，我们可以在每个子区间上构造一个三次 Hermite 插值多项式来进行插值。具体地，在每个子区间 $[x_i, x_{i+1}]$ 上，我们构造 $s_i(x) = a_i x^3 + b_i x^2 + c_i x + d_i$，使得

- $s_i(x_i) = f(x_i)$, $s_i(x_{i+1}) = f(x_{i+1})$ （函数值相同）
- $s_i'(x_i) = f'(x_i)$, $s_i'(x_{i+1}) = f'(x_{i+1})$ （导数值相同）

这样构造出来的插值多项式是连续一阶可微的。它的误差界是

$$\|s(x) - f(x)\|_\infty \leq \frac{\|f^{(4)}(x)\|_\infty}{384} h^4,$$

其中 $h = \max_{1 \leq i \leq n-1}(x_{i+1} - x_i)$ 是相邻数据点之间的最大距离。证明方法和线性样条插值类似，这里不再赘述。

3.3 三次样条插值

与上面的三次 Hermite 插值不同，三次样条插值不需要函数在每个采样点的导数值——它只需要函数值。假设我们的数据点为 $(x_0, y_0), (x_1, y_1), \ldots, (x_n, y_n)$. 同样地，我们在每个子区间 $[x_i, x_{i+1}]$ 上构造一个三次多项式 s_i 进行插值。这个三次多项式序列需要满足

- 连续性：$s_i(x_i) = f(x_i)$, $s_i(x_{i+1}) = f(x_{i+1})$, $\forall i = 0, 1, \ldots, n-1$.
- 一阶导数连续性：$s_i'(x_{i+1}) = s_{i+1}'(x_{i+1})$, $\forall i = 0, 1, \ldots, n-2$.
- 二阶导数连续性：$s_i''(x_{i+1}) = s_{i+1}''(x_{i+1})$, $\forall i = 0, 1, \ldots, n-2$.

按理来说，三次函数有四个参数，我们有 n 个区间，因此我们有 $4n$ 个自由度。函数值的要求提供了 $2n$ 个限制条件，一阶导数和二阶导数的要求分别提供了 $n-1$ 个限制条件，因此我们总共有 $4n-2$ 个限制条件。这样是没有定解的，我们还需要额外的两个限制条件来保证解的唯一性。

3.3.1 定解条件

常见的定解条件包括

1. **完全样条插值**：$s_0'(x_0) = k_0$, $s_{n-1}'(x_n) = k_n$;
2. **自然样条插值**：$s_0''(x_0) = s_{n-1}''(x_n) = 0$;

3. **周期样条插值**（若 $f(x_0)=f(x_n)$）：$s_0'(x_0)=s_{n-1}'(x_n)$, $s_0''(x_0)=s_{n-1}''(x_n)$.

4. **Not-a-knot 条件**：$s_0'''(x_1)=s_1'''(x_1)$, $s_{n-2}'''(x_{n-1})=s_{n-1}'''(x_{n-1})$.

最后一个条件之所以叫“Not-a-knot”，是因为它要求在 x_1 和 x_{n-1} 处的三阶导数值相同，这就相当于把 x_1 和 x_{n-1} 这两个节点“打平”，在三次多项式视角下我们无法分辨出它是节点还是内部点了，因此叫“Not-a-knot”.

3.3.2 矩阵形式

接下来我们考虑三次样条插值多项式的求解。假设在 $[x_i,x_{i+1}]$ 区间上，我们构造的三次多项式为 $s_i(x)$，下面我们通过构造基函数，来求解这个多项式。假设我们需要

$$\begin{cases} s_i(x_i)=y_i \\ s_i(x_{i+1})=y_{i+1} \\ s_i'(x_i)=k_i \\ s_i'(x_{i+1})=k_{i+1} \end{cases}$$

于是，我们可以考虑构造下面四个基函数：

- $\phi_i(x)$: 满足 $\phi_i(x_i)=1$, $\phi_i(x_{i+1})=0$, $\phi_i(x_i)=\phi_i(x_{i+1}=0)$;
- $\phi_{i+1}(x)=\phi(x_i+x_{i+1}-x)$.
- $\psi_i(x)$: 满足 $\psi_i(x_i)=\psi_i(x_{i+1})=0$, $\psi_i'(x_i)=1$, $\psi_i'(x_{i+1})=0$.
- $\psi_{i+1}(x)=-\psi(x_i+x_{i+1}-x)$.

假如我们得到了上面四个基函数，那么我们就可以将 $s_i(x)$ 表示为

$$s_i(x)=y_i\phi_i(x)+y_{i+1}\phi_{i+1}(x)+k_i\psi_i(x)+k_{i+1}\psi_{i+1}(x).$$

接下来我们需要求解上面四个基函数的具体表达式。为了表达式的简洁，我们先将区间 $[x_i,x_{i+1}]$ 映射到 $[0,1]$ 上，即 $t=\frac{x-x_i}{x_{i+1}-x_i}=\frac{x-x_i}{h_i}$. 接下来，我们记 $\phi(x)=g\circ t(x)$, $\psi(x)=z\circ t(x)$. 接下来，我们只需求解 $g_i(t)$ 和 $z_i(t)$.

先看 $g_i(t)$. 由于它在 1 处取值 0，且导数也为零，这说明零点至少两重，因此它有一个因子 $(1-t)^2=1-2t+t^2$. 为使 g_i 在 0 处取值 1，它应该还有一个因子是 $1+\lambda t$. Taylor 展开告诉我们，g_i 的一次项系数就是 $g_i'(0)$. 显然我们应该让 $\lambda=2$ 以消去一次项。因此 $g_i(t)=(1+2t)(1-t)^2$.

同样地，$z_i(t)$ 在 0 处有一重根，在 1 处有两重根，因此它可以写成 $Ct(1-t)^2$. 显然一次项系数是 C，因此我们需要让 $C=1$，即 $z_i(t)=t(1-t)^2$.

因此，我们得到了 s_i 的表达式

$$s_i(x) = (y_i g_i + y_{i+1} g_{i+1} + k_i h_i z_i + k_{i+1} h_i z_{i+1}) \circ t(x).$$

这个方程对我们来说未知量有两个：两个导数值 k_i 和 k_{i+1}. 由于二阶导数值的连续性要求，我们还需计算 s_i 的二阶导。事实上，$s_i''(x_{i+1}) = s_{i+1}''(x_{i+1})$ 等价于

$$6\frac{y_i}{h_i^2} - 6\frac{y_{i+1}}{h_i^2} + 2\frac{k_i}{h_i} + 4\frac{k_{i+1}}{h_i} = -6\frac{y_{i+1}}{h_{i+1}^2} + 6\frac{y_{i+2}}{h_{i+1}^2} - 4\frac{k_{i+1}}{h_{i+1}} - 2\frac{k_{i+2}}{h_{i+1}}.$$

如果我们定义

$$\begin{cases} h_i = x_{i+1} - x_i & i = 0, 1, \ldots, n-1 \\ \beta_i = \frac{1}{h_i} & i = 0, 1, \ldots, n-1 \\ \alpha_{i+1} = 2(\beta_i + \beta_{i+1}) & i = 0, 1, \ldots, n-2 \\ \eta_i = 3 \cdot \frac{y_{i+1} - y_i}{h_i^2} & i = 0, 1, \ldots, n-1 \end{cases},$$

那么上面的方程就可以写成

$$\beta_i k_i + \alpha_{i+1} k_{i+1} + \beta_{i+1} k_{i+2} = \eta_i + \eta_{i+1}.$$

这是一个三对角线性方程组。它实际上是我们的第 2 到 $n-1$ 个方程。第一个和最后一个方程需要根据定解条件来写出。

1. **完全样条插值**：$s_0'(x_0) = k_0$, $s_{n-1}'(x_n) = k_n$. 于是方程组为

$$\begin{cases} \alpha_1 k_1 + \beta_1 k_2 = \eta_0 + \eta_1 - \beta_0 k_0 & i = 0 \\ \beta_i k_i + \alpha_{i+1} k_{i+1} + \beta_{i+1} k_{i+2} = \eta_i + \eta_{i+1} & i = 1, 2, \ldots, n-3 \\ \beta_{n-2} k_{n-2} + \alpha_{n-1} k_{n-1} = \eta_{n-2} + \eta_{n-1} - \beta_{n-1} k_n & i = n-2 \end{cases}$$

   这等价于

$$\begin{bmatrix} \alpha_1 & \beta_1 & & & \\ \beta_1 & \alpha_2 & \beta_2 & & \\ & \beta_2 & \ddots & \ddots & \\ & & \ddots & \alpha_{n-2} & \beta_{n-2} \\ & & & \beta_{n-2} & \alpha_{n-1} \end{bmatrix} \begin{bmatrix} k_1 \\ k_2 \\ \vdots \\ k_{n-2} \\ k_{n-1} \end{bmatrix} = \begin{bmatrix} \eta_0 + \eta_1 - \beta_0 k_0 \\ \eta_1 + \eta_2 \\ \vdots \\ \eta_{n-3} + \eta_{n-2} \\ \eta_{n-2} + \eta_{n-1} - \beta_{n-1} k_n \end{bmatrix}$$

   由 α_i 的定义可知，上面的系数矩阵是严格对角占优的，因此我们可以直接用不选主元的 Gauss 消去法来求解，求解的代价是 $O(n)$.

2. **自然样条插值**：$s_0''(x_0) = s_{n-1}''(x_n) = 0$. 于是方程组为

$$\begin{cases} 2\beta_0 k_0 + \beta_0 k_1 = \eta_0 & \text{Additional Condition} \\ \beta_i k_i + \alpha_{i+1} k_{i+1} + \beta_{i+1} k_{i+2} = \eta_i + \eta_{i+1} & i = 0, 1, \ldots, n-2 \\ \beta_{n-1} k_{n-1} + 2\beta_{n-1} k_n = \eta_{n-1} & \text{Additional Condition} \end{cases}$$

这等价于

$$\begin{bmatrix} 2\beta_0 & \beta_0 & & & & & \\ \beta_0 & \alpha_1 & \beta_1 & & & & \\ & \beta_1 & \alpha_2 & \beta_2 & & & \\ & & \beta_2 & \ddots & \ddots & & \\ & & & \ddots & \alpha_{n-2} & \beta_{n-2} & \\ & & & & \beta_{n-2} & \alpha_{n-1} & \beta_{n-1} \\ & & & & & \beta_{n-1} & 2\beta_{n-1} \end{bmatrix} \begin{bmatrix} k_0 \\ k_1 \\ k_2 \\ \vdots \\ k_{n-2} \\ k_{n-1} \\ k_n \end{bmatrix} = \begin{bmatrix} \eta_0 \\ \eta_0+\eta_1 \\ \eta_1+\eta_2 \\ \vdots \\ \eta_{n-3}+\eta_{n-2} \\ \eta_{n-2}+\eta_{n-1} \\ \eta_{n-1} \end{bmatrix}$$

这是一个严格对角占优的 $n+1$ 阶三对角矩阵，可使用不选主元的 Gauss 消去法求解。

3. **周期样条插值：** $s_0'(x_0)=s_n'(x_n)$, $s_0''(x_0)=s_n''(x_n)$. 于是方程组为

$$\begin{cases} \alpha_0 k_0+\beta_0 k_1+\beta_{n-1}k_{n-1}=\eta_0+\eta_1 & \text{Additional condition, where } \alpha_0=2(\beta_0+\beta_{n-1}) \\ \beta_i k_i+\alpha_{i+1}k_{i+1}+\beta_{i+1}k_{i+2}=\eta_i+\eta_{i+1} & i=0,1,\ldots,n-2 \\ \beta_{n-1}k_0+\beta_{n-2}k_{n-2}+\alpha_{n-1}k_{n-1}=\eta_{n-2}+\eta_{n-1} & \text{Additional condition.} \end{cases}$$

这等价于

$$\begin{bmatrix} \alpha_0 & \beta_0 & 0 & \cdots & 0 & \beta_{n-1} \\ \beta_0 & \alpha_1 & \beta_1 & \cdots & 0 & 0 \\ 0 & \beta_1 & \alpha_2 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & \alpha_{n-2} & \beta_{n-2} \\ \beta_{n-1} & 0 & 0 & \cdots & \beta_{n-2} & \alpha_{n-1} \end{bmatrix} \begin{bmatrix} k_0 \\ k_1 \\ k_2 \\ \vdots \\ k_{n-2} \\ k_{n-1} \end{bmatrix} = \begin{bmatrix} \eta_0+\eta_1 \\ \eta_1+\eta_2 \\ \eta_2+\eta_3 \\ \vdots \\ \eta_{n-3}+\eta_{n-2} \\ \eta_{n-2}+\eta_{n-1} \end{bmatrix}$$

这是一个 n 阶严格对角占优的循环三对角矩阵，可以使用不选主元的 Gauss 消去法求解，代价为 $O(n)$.

4. **Not-a-knot 条件：** $s_0'''(x_1)=s_1'''(x_1)$, $s_{n-2}'''(x_{n-1})=s_{n-1}'''(x_{n-1})$. 于是方程组为

$$\begin{cases} 3\beta_0 k_0+3\left(\beta_0-\frac{\beta_1^2}{\beta_0}\right)k_1-3\frac{\beta_1^2}{\beta_0}k_2=2\left(\eta_0-\frac{\beta_1}{\beta_0}\eta_1\right) & \text{Additional Condition} \\ \beta_i k_i+\alpha_{i+1}k_{i+1}+\beta_{i+1}k_{i+2}=\eta_i+\eta_{i+1} & i=0,1,\ldots,n-2 \\ 3\beta_{n-2}k_{n-2}+3\left(\beta_{n-2}-\frac{\beta_{n-1}^2}{\beta_{n-2}}\right)k_{n-1}-3\frac{\beta_{n-1}^2}{\beta_{n-2}}k_n=2\left(\eta_{n-2}-\frac{\beta_{n-1}}{\beta_{n-2}}\eta_{n-1}\right) & \text{Additional Condition} \end{cases}$$

这等价于

$$\begin{bmatrix} 3\beta_0 & 3\left(\beta_0-\frac{\beta_1^2}{\beta_0}\right) & -3\frac{\beta_1^2}{\beta_0} & & & & \\ \beta_0 & \alpha_1 & \beta_1 & & & & \\ 0 & \beta_1 & \alpha_2 & \beta_2 & & & \\ & & \ddots & \ddots & \ddots & & \\ & & & \beta_{n-3} & \alpha_{n-2} & \beta_{n-2} \\ & & & 0 & \beta_{n-2} & 3\left(\beta_{n-2}-\frac{\beta_{n-1}^2}{\beta_{n-2}}\right) \end{bmatrix} \begin{bmatrix} k_0 \\ k_1 \\ k_2 \\ \vdots \\ k_{n-2} \\ k_{n-1} \\ k_n \end{bmatrix} = \begin{bmatrix} 2\left(\eta_0-\frac{\beta_1}{\beta_0}\eta_1\right) \\ \eta_0+\eta_1 \\ \eta_1+\eta_2 \\ \vdots \\ \eta_{n-3}+\eta_{n-2} \\ 2\left(\eta_{n-2}-\frac{\beta_{n-1}}{\beta_{n-2}}\eta_{n-1}\right) \end{bmatrix}$$

尽管这并不是一个严格对角占优的矩阵，但使用不选主元的 Gauss 消去法求解也是没有问题的，代价为 $O(n)$.

完全样条和自然样条是最常用的两种三次样条插值方法。周期样条适用于周期函数的插值，而 Not-a-knot 条件则适用于节点分布不均匀的情况。完全样条和自然样条的误差界为（下设 $h = \max_{0\le i\le n-1}|x_{i+1}-x_i|$）

$$\|s(x)-f(x)\|_\infty \le \frac{\|f^{(4)}(x)\|_\infty}{16}h^4$$
$$\|s'(x)-f'(x)\|_\infty \le \frac{\|f^{(4)}(x)\|_\infty}{2}h^3$$
$$\|s''(x)-f''(x)\|_\infty \le \frac{\|f^{(4)}(x)\|_\infty}{2}h^2$$

可以看出，k 阶导数的误差阶为 $O(h^{4-k})$，由 Taylor 展开可知，这个误差阶是最优的。

样条函数具有良好的数学性质。三次样条能够最小化弹性势能

$$E[s] = \int_a^b [s''(x)]^2\,\mathrm{d}x.$$

具体地，对于任意给定的光滑函数 $f:\mathbb{R}\to\mathbb{R}$，定义如下仿射空间

$$\mathcal{W}_0 := \{g\in C^2[a,b] : g(x_i)=f(x_i),\quad \forall i=1,\dots,n\}$$
$$\mathcal{W}_1 := \{g\in \mathcal{W}_0 : g'(x_0)=f'(x_0),\quad g'(x_n)=f'(x_n)\}$$

3.1 定理

- 设 $s(x)$ 是 f 的自然样条插值函数，则对任意 $g\in\mathcal{W}_0$，都有 $E[s]\le E[g]$.
- 设 $s(x)$ 是 f 的完全样条插值函数，则对任意 $g\in\mathcal{W}_1$，都有 $E[s]\le E[g]$.

证明. 设 $g = s + tv$，则 $v(x_i) = 0, \forall i = 1, \ldots, n$. 考虑

$$
\begin{aligned}
E[g] &= E[s + tv] \\
&= \int_a^b [s''(x) + tv''(x)]^2 \,\mathrm{d}x \\
&= E[s] + 2t \int_a^b s''(x)v''(x) \,\mathrm{d}x + t^2 E[v] \\
&\geq E[s] + 2t \int_a^b s''(x)v''(x) \,\mathrm{d}x \\
&= E[s] + 2t \sum_{i=1}^{n-1} \int_{x_i}^{x_{i+1}} s''(x) \,\mathrm{d}v'(x) \quad \text{分部积分} \\
&= E[s] + 2t \sum_{i=1}^{n-1} \left[s''(x)v'(x)\Big|_{x_i}^{x_{i+1}} - \int_{x_i}^{x_{i+1}} s'''(x)v'(x) \,\mathrm{d}x \right] \\
&= E[s] + 2t \sum_{i=1}^{n-1} \left[s''(x)v'(x)\Big|_{x_i}^{x_{i+1}} - \int_{x_i}^{x_{i+1}} s'''(x) \,\mathrm{d}v(x) \right] \\
&= E[s] + 2t \sum_{i=1}^{n-1} \left[s''(x)v'(x)\Big|_{x_i}^{x_{i+1}} - s'''(x)v(x)\Big|_{x_i}^{x_{i+1}} + \int_{x_i}^{x_{i+1}} s^{(4)}(x)v(x) \,\mathrm{d}x \right] \\
&= E[s] + 2t \sum_{i=1}^{n-1} \left[(s''(x)v'(x) - s'''(x)v(x))\Big|_{x_i}^{x_{i+1}} \right] \quad \text{因为 } s^{(4)} \equiv 0 \\
&= E[s] + 2t \sum_{i=1}^{n-1} [s''(b)v'(b) - s''(a)v'(a)] \quad \text{由 } s'' \text{ 的连续性和 } v(x_i) = 0 \text{ 易知}
\end{aligned}
$$

当 s 是自然样条插值函数时，$s''(a) = s''(b) = 0$，因此 $E[g] \geq E[s]$.

当 s 是完全样条插值函数时，由 $g \in \mathcal{W}_1$ 可知，

$$
\begin{aligned}
g'(a) = f'(a) = s'(a) &\implies v'(a) = 0 \\
g'(b) = f'(b) = s'(b) &\implies v'(b) = 0
\end{aligned}
$$

因此 $E[g] \geq E[s]$. □