STAT50017.01 随机过程导论 Spring 2026

Lecture 3 概率论复习（三） — 2026.03.20

Instructor: 王勤文

Scribe: 路人甲

吴波的恩情还不完!

目录

1 随机变量的相互独立 **1**

2 概率不等式 **3**

3 随机序列的收敛 **6**

1 随机变量的相互独立

我们首先来探讨随机变量的独立性。对于 n 个随机变量，它们相互独立的定义可以由其累积分布函数（CDF）的乘积形式给出：

1.1 定义

$X_1, X_2, \ldots, X_n$ 相互独立指：

$$F(x_1, x_2, \ldots, x_n) = F_1(x_1)F_2(x_2)\cdots F_n(x_n), \quad \forall x_1, x_2, \ldots, x_n \in \mathbb{R} \cup \{\pm\infty\}.$$

这在离散和连续情况下分别等价于它们的概率质量函数（PMF）或概率密度函数（PDF）能够分解为边缘概率的乘积：

$$p(x_1, x_2, \ldots, x_n) = p(x_1)p(x_2)\ldots p(x_n) \quad \text{(离散情况)}$$
$$f(x_1, x_2, \ldots, x_n) = f(x_1)f(x_2)\ldots f(x_n) \quad \text{(连续情况)}$$

那么，在频域或者变换域中，独立性具有怎样的代数特征呢？注意到，这也等价于联合矩母函数能够分解为各边缘矩母函数的乘积：

$$M_X(t_1, t_2, \ldots, t_n) = \mathbb{E}(\mathrm{e}^{t^\top X}) = M_{X_1}(t_1)\ldots M_{X_n}(t_n) \quad \text{(矩母函数)}$$

基于上述定义，我们自然会问：如果一组随机变量是相互独立的，它们的子集或者经过函数变换后，独立性是否依然保持？我们有如下推论：

1.2 推论

1. 若 $X_1, \ldots, X_n$ 相互独立，则它们的任意子集 $X_1, \ldots, X_k$ 也是相互独立的 $(2 \leq k \leq n-1)$。
2. 若 $X_1, \ldots, X_n$ 相互独立，则对于任意函数 g 和 h，$g(X_1, \ldots, X_k)$ 与 $h(X_{k+1}, \ldots, X_n)$ 也是相互独立的。

证明. (1) 在定义式中，取 $x_{k+1}, \ldots, x_n = +\infty$，由 $F_k(+\infty) = 1$ 易知结论成立。

(2) 为了说明函数变换后的变量依然独立，我们可以计算它们的联合矩母函数，并验证其是否可以分解：

$$\begin{aligned}
M_{(g,h)}(t,s) &= \mathbb{E}\mathrm{e}^{tg(X_1,\ldots,X_k)+sh(X_{k+1},\ldots,X_n)} \\
&= \int \mathrm{e}^{tg(x_1,\ldots,x_k)+sh(x_{k+1},\ldots,x_n)} f(x_1,\ldots,x_n)dx_1\ldots dx_n \\
&= \int \mathrm{e}^{tg(x_1,\ldots,x_k)} \cdot \mathrm{e}^{sh(x_{k+1},\ldots,x_n)} f(x_1)\ldots f(x_n)dx_1\ldots dx_n \\
&= \left(\int \mathrm{e}^{tg(x_1,\ldots,x_k)} f(x_1,\ldots,x_k)dx_1\ldots dx_k\right) \\
&\left(\int \mathrm{e}^{sh(x_{k+1},\ldots,x_n)} f(x_{k+1})\ldots f(x_n)dx_{k+1}\ldots dx_n\right) \\
&= M_g(t)\cdot M_h(s).
\end{aligned}$$

这一推导清晰地展示了，由于原变量互相独立，联合密度函数的重积分自然退化为两个独立块的积分乘积，从而从代数层面上保证了变换后特征的彻底解耦。 □

除了保持独立性之外，独立同分布的随机变量的求和经常会产生一些经典的分布。我们来看两个常见的例子：

1.3 推论

若 $\{\xi_i\} \overset{i.i.d.}{\sim} \mathrm{Bernoulli}(p)$，则它们的和服从二项分布：$\sum_{i=1}^n \xi_i \sim B(n,p)$。
若 $\{\xi_i\} \overset{i.i.d.}{\sim} \exp(\lambda)$，则它们的和服从 Gamma 分布：$\sum_{i=1}^n \xi_i \sim \Gamma(n,\lambda)$。

证明. 接下来，我们利用矩母函数对第一个结论进行证明，第二个结论的证明同理。注意到，独立变量和的矩母函数等于各自矩母函数的连乘积：

$$M_{\sum_{i=1}^n \xi_i}(t) = \mathbb{E}\left[\mathrm{e}^{t\sum_{i=1}^n \xi_i}\right] = \mathbb{E}\left[\prod_{i=1}^n \mathrm{e}^{t\xi_i}\right] = \prod_{i=1}^n \mathbb{E}\mathrm{e}^{t\xi_i} = (p\mathrm{e}^t + 1 - p)^n$$

显然这是二项分布 $B(n,p)$ 的矩母函数，故由唯一性定理可知 $\sum_{i=1}^{n}\xi_i \sim B(n,p)$.

通过引入矩母函数，我们巧妙地将复杂的概率卷积运算转化为了简单的代数乘法运算，极大地简化了分布族封闭性的证明。 □

探讨完独立性，一个自然的问题是：如果两个随机变量不独立，我们该如何衡量它们之间的线性相关程度呢？由此我们引入协方差的定义：

1.4 定义

两个随机变量的协方差定义为：

$$\operatorname{cov}(X_1,X_2)=\mathbb{E}(X_1-\mathbb{E}X_1)(X_2-\mathbb{E}X_2)^\top=\mathbb{E}(X_1X_2^\top)-(\mathbb{E}X_1)(\mathbb{E}X_2)^\top.$$

显然，如果两个随机变量相互独立，即 $X_1 \perp\!\!\!\perp X_2$，那么它们的乘积期望可分，即 $\mathbb{E}(X_1X_2)=\mathbb{E}(X_1)\mathbb{E}(X_2)$，此时协方差为零。这说明独立必定不相关。

2 概率不等式

在概率论中，很多时候我们无法确切知道随机变量的完整分布。那么，仅仅依赖期望和方差等粗略信息，我们能否对变量偏离均值的概率给出一个有用的上界呢？这便引出了概率不等式的概念。

2.1 定理 *Markov* 不等式

设有非负随机变量 $X\geq 0$. 对任意 $a\geq 0$，我们都有

$$\mathbb{P}(X\geq a)\leq \frac{\mathbb{E}(X)}{a}.$$

我们把这个不等式称为 Markov 不等式。这是一个非常松的上界。

证明. 我们利用示性函数来放缩。构造如下不等式：

$$a\cdot \mathbf{1}_{\{X\geq a\}}=\begin{cases} a & X\geq a \\ 0 & X<a \end{cases} \Rightarrow a\cdot \mathbf{1}_{\{X\geq a\}}\leq X$$

我们在两边同时取期望，立刻得到：$a\mathbb{P}(X\geq a)\leq \mathbb{E}X$，移项后即得待证不等式。从几何意义上看，Markov 不等式本质上是用一个加权的阶跃函数来从下方逼近非负随机变量自身，从而实现对尾部概率的控制。

Markov 不等式是一个非常松的界：考虑 $X \sim \mathcal{N}(0,1)$. 由 Markov 不等式，我们有

$$\mathbb{P}(|X| \geq 3) \leq \frac{\mathbb{E}|X|}{3} = \frac{\sqrt{2/\pi}}{3} \approx 0.265.$$

然而，标准正态分布的实际尾部概率 $\mathbb{P}(|X| \geq 3)$ 约为 0.0027，远远小于 Markov 不等式给出的界。这说明 Markov 不等式虽然提供了一个通用的上界，但给出的界过于宽松，在实际应用中往往无法反映随机变量的真实尾部行为。 □

既然 Markov 不等式的界比较松，那如果加上高阶矩信息，我们能不能得到更紧的界呢？当然可以。

2.2 定理 *Chebyshev* 不等式

若随机变量 X 的均值为 μ，$X-\mu$ 的 m 阶矩有限，即 $\mathbb{E}|X-\mu|^m < +\infty$，则对任意的 $a > 0$，我们都有

$$\mathbb{P}(|X-\mu| \geq a) \leq \frac{\mathbb{E}|X-\mu|^m}{a^m}.$$

我们称这个不等式为 Chebyshev 不等式，它提供的界一般要比 Markov 不等式更紧。特别地，如果我们取 $m=2$，有

$$\mathbb{P}(|X-\mu| \geq a) \leq \frac{\sigma^2}{a^2},$$

其中 σ^2 是随机变量 X 的方差。如果我们取 $a = 3\sigma$，我们可以得到

$$\mathbb{P}(|X-\mu| \geq 3\sigma) \leq \frac{1}{9}.$$

这说明随机变量 X 有至少 8/9 的数据分布在均值附近 3σ 范围内。

证明. 我们同样使用示性函数的方法进行放缩，只是此时我们考察的是偏离均值的平方：

$$\mathbf{1}_{\{|X-\mu|\geq t\}} = \begin{cases} 1, & |X-\mu| \geq t \Leftrightarrow \left(\frac{|X-\mu|}{t}\right)^m \geq 1 \\ 0, & |X-\mu| < t \end{cases}$$

由此可推导：

$$\Rightarrow \mathbf{1}_{\{|X-\mu|\geq t\}} \leq \frac{|X-\mu|^m}{t^m} \Rightarrow \mathbb{P}(|X-\mu| \geq t) \leq \frac{\mathbb{E}|X-\mu|^m}{t^m}$$

这实际上是将 Markov 不等式巧妙地应用到了非负随机变量 $(X-\mu)^m$ 上。它直观地揭示了方差直接决定了随机变量向其期望值集中的程度。 □

我们知道，高阶矩可以由矩母函数/特征函数表示。那么，如果我们知道整个矩母函数/特征函数，我们能不能得到更紧的界呢？

2.3 定理 *Chernoff* 界

设随机变量 X 的矩母函数是 $\phi(t)$，则对任意 $a > 0$，都有

$$\begin{cases} \mathbb{P}(X \geq a) \leq \mathrm{e}^{-ta} \cdot \phi(t) & \text{for } t > 0 \\ \mathbb{P}(X \leq a) \leq \mathrm{e}^{-ta} \cdot \phi(t) & \text{for } t < 0 \end{cases}$$

这个不等式是基于矩母函数的分析工具。它通常能给出指数级别的尾部概率衰减。

证明. 注意到 $\mathbb{P}(X \geq a) = \mathbb{P}(\exp(tX) \geq \exp(ta))$，然后应用 Markov 不等式，有

$$\mathbb{P}(X \geq a) \leq \exp(-ta)\mathbb{E}(\exp(tX)) = \mathrm{e}^{-ta} \cdot \phi(t), \quad t > 0.$$

$t < 0$ 的情况同理。 □

在很多应用场景中，Chernoff 不等式比 Chebyshev 不等式要紧致得多。因为这个不等式对所有的 t 都成立，所以我们可以对 t 取下确界来寻找最严苛的上界：

$$\mathbb{P}(X \geq a) \leq \inf_{t>0} \mathrm{e}^{-ta} \cdot \phi(t).$$

2.4 例

设 $X \sim \mathcal{N}(\mu, \sigma^2)$. 证明：

$$\mathbb{P}(X \geq a) \leq \exp\left(\frac{(a-\mu)^2}{2\sigma^2}\right), \quad \forall a > \mu.$$

证明. 由于 $(X-\mu)/\sigma \sim \mathcal{N}(0,1)$，而标准正态分布的矩母函数是 $\phi(t) = \exp(t^2/2)$，由 Chernoff 不等式，我们有

$$\begin{aligned} \mathbb{P}(X \geq a) &= \mathbb{P}\left(\frac{X-\mu}{\sigma} \geq \frac{a-\mu}{\sigma}\right) \\ &\leq \inf_{t>0} \exp\left(-t \cdot \frac{a-\mu}{\sigma}\right) \cdot \exp\left(\frac{t^2}{2}\right) \\ &= \inf_{t>0} \exp\left(-t \cdot \frac{a-\mu}{\sigma} + \frac{1}{2}t^2\right) \\ &= \exp\left(-\frac{(a-\mu)^2}{2\sigma^2}\right). \end{aligned}$$

倘若我们使用 Chebyshev 不等式，我们得到的界是

$$\begin{aligned}\mathbb{P}(X \geq a) &= \mathbb{P}(X - \mu \geq a - \mu) \\ &= \frac{1}{2}\mathbb{P}(|X - \mu| \geq a - \mu) \\ &\leq \frac{1}{2} \cdot \frac{\sigma^2}{(a-\mu)^2}.\end{aligned}$$

显然，Chernoff 不等式得到的界是 $O(\exp(-(a-\mu)^2))$ 级别的，是亚高斯衰减的（所谓亚高斯就是衰减速度和 Gauss 分布一样或更快），而 Chebyshev 不等式得到的界是 $O((a-\mu)^{-2})$ 级别的，是多项式衰减的。显然前者的界是更优的。 □

3 随机序列的收敛

讨论完单个随机变量的概率边界后，我们接下来探讨随机变量序列的渐进性质。我们重点关注以下四种核心的收敛形式：依分布收敛、依概率收敛、几乎处处收敛和 L^p 收敛。

3.1 定义 依概率收敛

设 $\{X_n\}_{n\in\mathbb{N}}$ 和 X 是定义在同一概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量。假设该空间配备了一个度量 d. 如果对于任意 $\varepsilon > 0$，都有

$$\lim_{n\to\infty} \mathbb{P}(\{\omega \in \Omega : d(X_n(\omega), X(\omega)) \geq \varepsilon\}) = 0,$$

则称 X_n 依概率收敛于 X，记作 $X_n \xrightarrow{p} X$.

注：有时我们也将上式中的集合 $\{\omega \in \Omega : d(X_n(\omega), X(\omega)) \geq \varepsilon\}$ 简写为 $\{d(X_n, X) \geq \varepsilon\}$，于是上式可简化为

$$\lim_{n\to\infty} \mathbb{P}(d(X_n, X) \geq \varepsilon) = 0.$$

在欧式空间中，常用的度量是 2–范数。如果随机变量是一维的，我们通常直接使用绝对值来度量它们之间的距离。

此外，上式还可以等价地表述为：对于任意 $\delta > 0$，存在 $N_\delta \in \mathbb{N}$，对于任意的 $\varepsilon > 0$，我们都有

$$\mathbb{P}(d(X_n, X) \geq \varepsilon) < \delta, \quad \forall n > N_\delta.$$

3.2 定义 依分布收敛

设 $\{X_n\}_{n\in\mathbb{N}}$ 和 X 是定义在同一概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量。设 F_n 和 F 分别是 X_n 和 X 的分布函数。如果对于任意的分布函数**连续点** t，都有

$$\lim_{n\to\infty} F_n(t) = F(t),$$

则称 X_n 依分布收敛于 X，记作 $X_n \xrightarrow{d} X$. 我们也称 F_n 弱收敛于 F，记作 $F_n \xrightarrow{w} F$.

依概率收敛和依分布收敛是两种不同强度的收敛。依概率收敛直接刻画了随机变量 X_n 向 X 靠近的行为，但依分布收敛则依靠分布函数来刻画收敛性——这是间接的刻画。从直觉上讲，依分布收敛肯定是比依概率收敛来得弱的。事实也是如此。依分布收敛并不能保证变量在样本空间上的靠近，推不出依概率收敛。一个经典的反例是：令 $X \sim \mathcal{N}(0,1)$，$Y = -X$，此时序列分布完全一致，但它们不可能依概率靠近。相反地，依概率收敛则必定能推出依分布收敛。从直觉上讲，如果随机变量序列在样本空间中以高概率无限接近目标，那么它反映在累积分布上必然也会逼近目标的分布。

3.3 定理

设随机序列 $\{X_n\}_{n\in\mathbb{N}}$ 依概率收敛于 X，即 $X_n \xrightarrow{p} X$，则 X_n 依分布收敛于 X，即 $X_n \xrightarrow{d} X$.

证明. 我们来严格证明依概率收敛可以推出依分布收敛。现在我们已知 $\lim_{n\to\infty} \mathbb{P}(d(X_n, X) \geq \varepsilon) = 0$.

要证依分布收敛，只需证对于任意的分布函数连续点 t，都有上极限 $\overline{\lim}_{n\to\infty} F_n(t) \leq F(t)$ 且下极限 $\underline{\lim}_{n\to\infty} F_n(t) \geq F(t)$.

首先考察下极限。要证明下极限比 $F(t)$ 大，我们只需证明当 n 充分大时，$F_n(t) \geq F(t)$. $F_n(t)$ 定义为 $\mathbb{P}(X_n \leq t)$. 为了将 X_n 与 X 联系起来，我们定义两个集合：

$$A = \{X_n \leq t\}$$
$$B = \{X \leq t - \varepsilon\}$$

$F_n(t) = \mathbb{P}(A)$. 由于交集的测度不会超过任一单独集合的测度，我们有：

$$\mathbb{P}(A) \geq \mathbb{P}(A \cap B) \iff F_n(t) \geq \mathbb{P}(X_n \leq t, X \leq t - \varepsilon).$$

这样，我们便成功地建立了 X_n 与 X 之间的联系。接下来我们的目标就是继续放缩这个交集的概率。由于我们最终希望得到 $F(t)$，亦即 $\mathbb{P}(B)$，我们不妨将 $A \cap B$ 写成 $B \setminus (B \setminus A)$，即

$$F_n(t) \geq \mathbb{P}(X \leq t - \varepsilon) - \mathbb{P}(X \leq t - \varepsilon, X_n > t).$$

第一项正是 $F(t-\varepsilon)$，而第二项说明 $d(X_n, X) \geq \varepsilon$，于是我们可以将第二项放大为 $\mathbb{P}(d(X_n, X) \geq \varepsilon)$，从而实现整体的缩小：

$$F_n(t) \geq F(t-\varepsilon) - \mathbb{P}(d(X_n, X) \geq \varepsilon).$$

接下来我们考虑右边的极限行为。对于任意的 $\delta > 0$，存在 $N_\delta \in \mathbb{N}$，使得对于任意 $n > N_\delta$，我们都有

$$\mathbb{P}(d(X_n, X) \geq \varepsilon) < \delta.$$

于是

$$F_n(t) \geq F(t-\varepsilon) - \delta, \quad \forall n > N_\delta.$$

又由于 F 在 t 处连续，我们可以找到一个 $\varepsilon_0 > 0$，使得对于任意的 $0 < \varepsilon < \varepsilon_0$，我们都有

$$F(t) \geq F(t-\varepsilon) > F(t) - \delta.$$

于是

$$F_n(t) \geq F(t) - 2\delta, \quad \forall n > N_\delta.$$

由 δ 的任意性，我们得到

$$F_n(t) \geq F(t), \quad \forall n > N_\delta.$$

由此可得：$\underline{\lim}_{n\to\infty} F_n(t) \geq F(t)$.

同理，对于上极限，我们有（以下省略具体的集合构造）：

$$\begin{aligned}
F(t+\varepsilon) &\triangleq \mathbb{P}(X \leq t+\varepsilon) \\
&\geq \mathbb{P}(X \leq t+\varepsilon, X_n \leq t) \\
&= \mathbb{P}(X_n \leq t) - \mathbb{P}(X_n \leq t, X > t+\varepsilon) \\
&\geq F_n(t) - \mathbb{P}(d(X_n, X) \geq \varepsilon) \\
&= F_n(t) - \delta
\end{aligned}$$

整理后得到：$F(t) \geq \overline{\lim}_{n\to\infty} F_n(t)$。

结合上下极限，最终得出：$\lim_{n\to\infty} F_n(t) = F(t)$。这表明，如果随机变量序列在度量空间中以高概率无限接近目标，那么它反映在累积分布上必然也会逼近目标的分布。 □

刚才提到依分布收敛一般无法推出依概率收敛，那么这个规则是否有例外呢？有的。如果序列逼近的目标退化为一个常数，那么这两种收敛性就是等价的：

$$X_n \xrightarrow{d} c \Rightarrow X_n \xrightarrow{p} c \quad (c \text{ 为常数})$$

我们给出简要的推导：分布函数 F 定义为

$$F(t) = \begin{cases} 0 & t < c \\ 1 & t \geq c \end{cases}$$

于是

$$
\begin{aligned}
\mathbb{P}(|X_n - c| \geq \varepsilon) &= \mathbb{P}(\{X_n \geq c + \varepsilon\} \cup \{X_n \leq c - \varepsilon\}) \\
&= \mathbb{P}(X_n \geq c + \varepsilon) + \mathbb{P}(X_n \leq c - \varepsilon) \quad \text{有限可加性} \\
&= 1 - F_n(c + \varepsilon) + F_n(c - \varepsilon) \\
&\to 0 \quad \text{as } n \to \infty.
\end{aligned}
$$

当极限分布完全集中在一点（阶跃函数）时，分布的收敛强制了变量数值本身的靠近，这也揭示了常数作为极限分布的特殊结构特征。